University of Applied Sciences and Arts Northwestern Switzerland
School of Business

member of
swissuniversities

AACSB
ACCREDITED

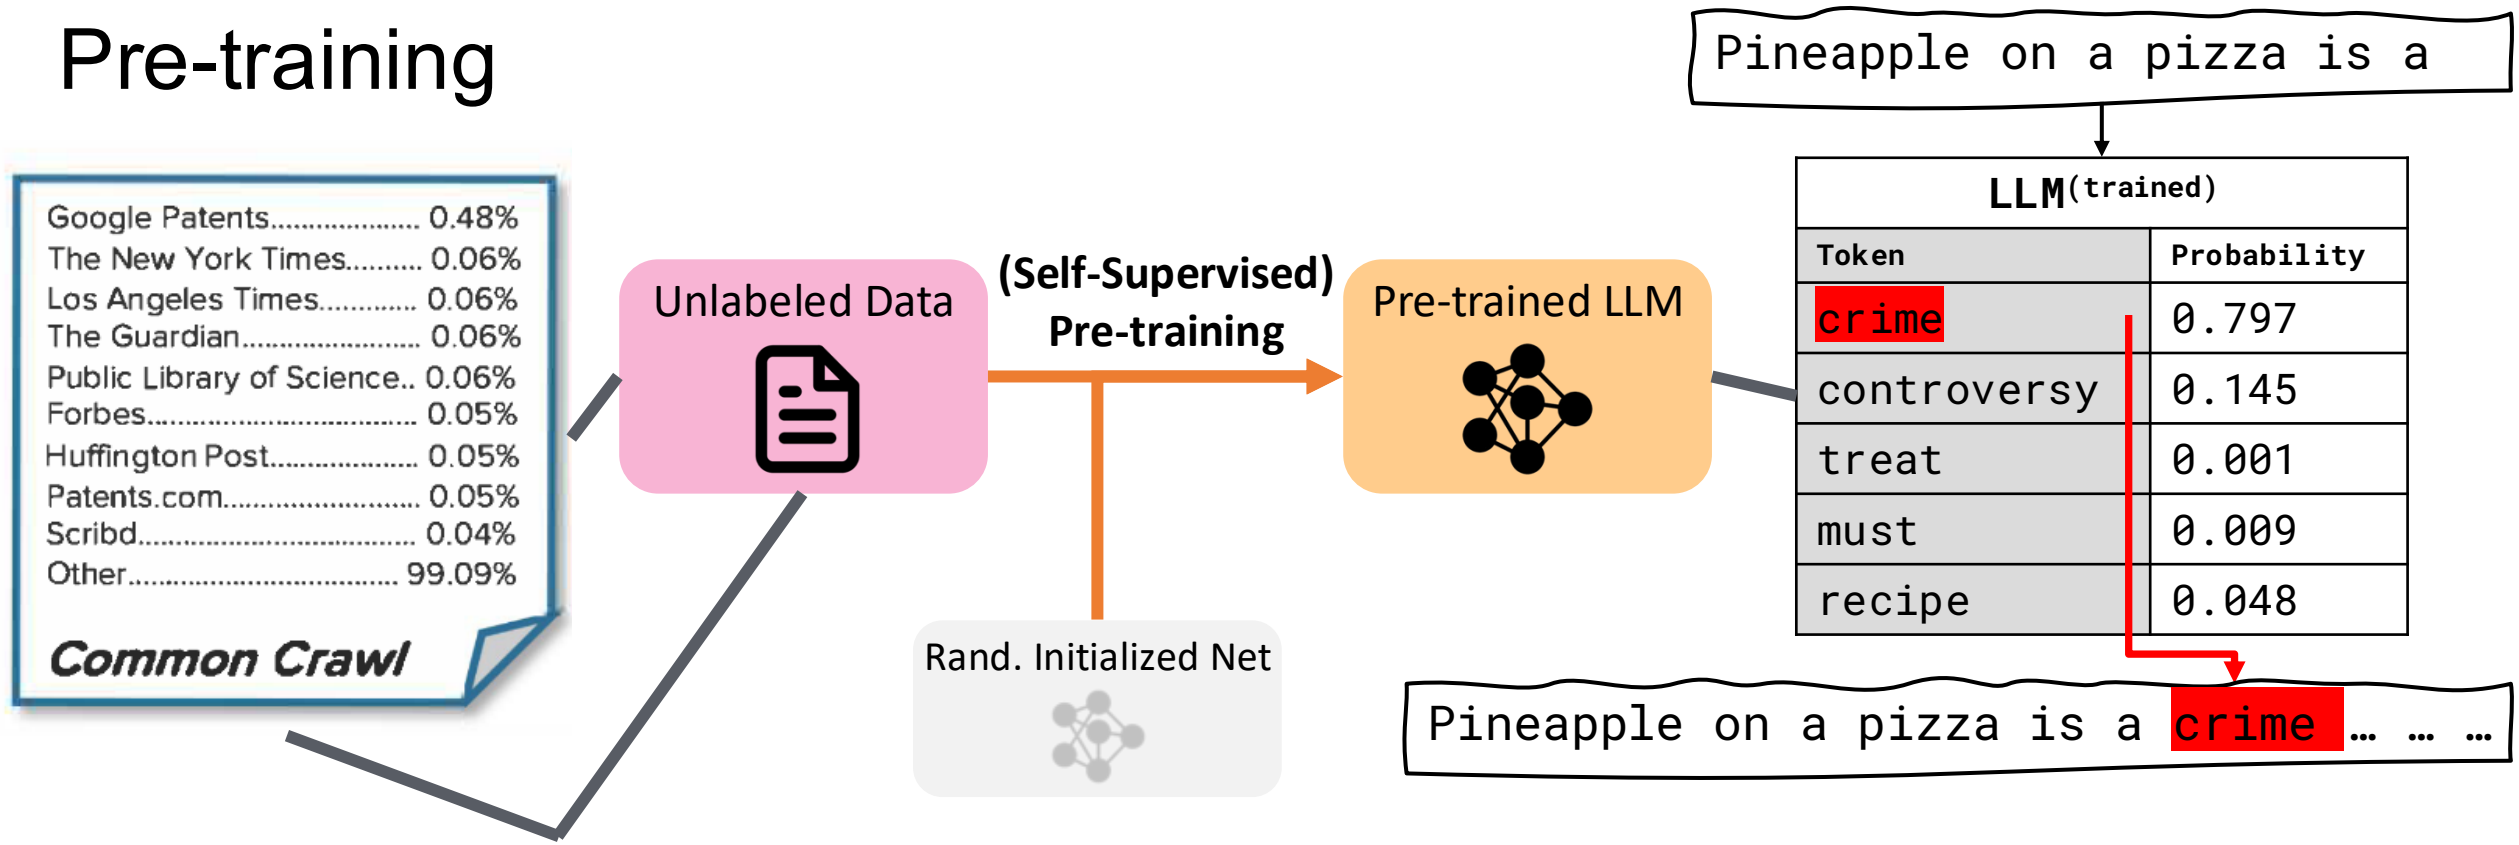
1 Generative AI, LLMs & Prompt Engineering

BSc BAI – Generative KI und Agentensysteme



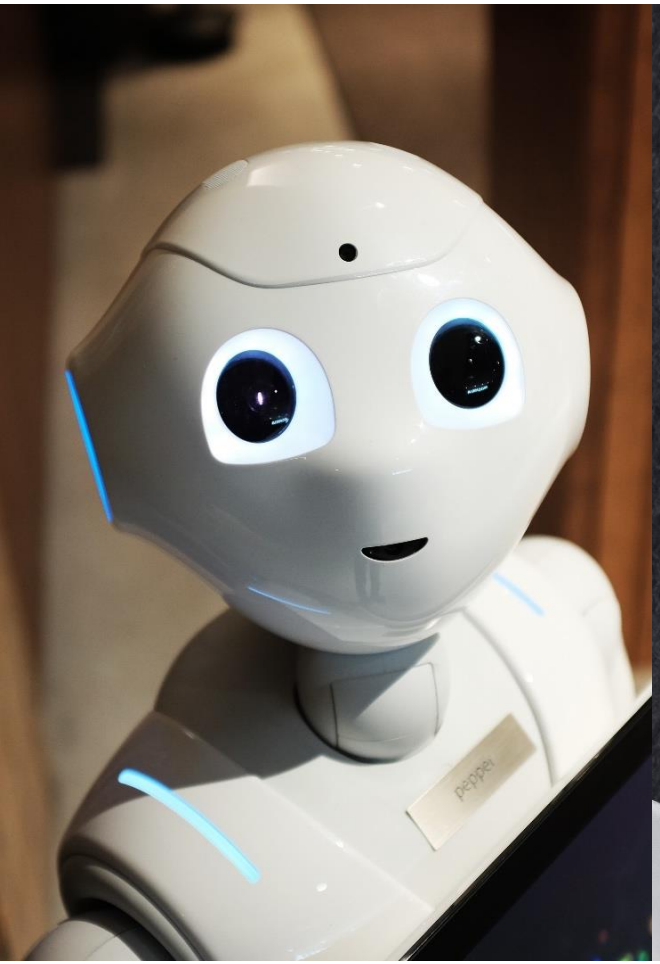
Prof. Dr. Andreas Martin

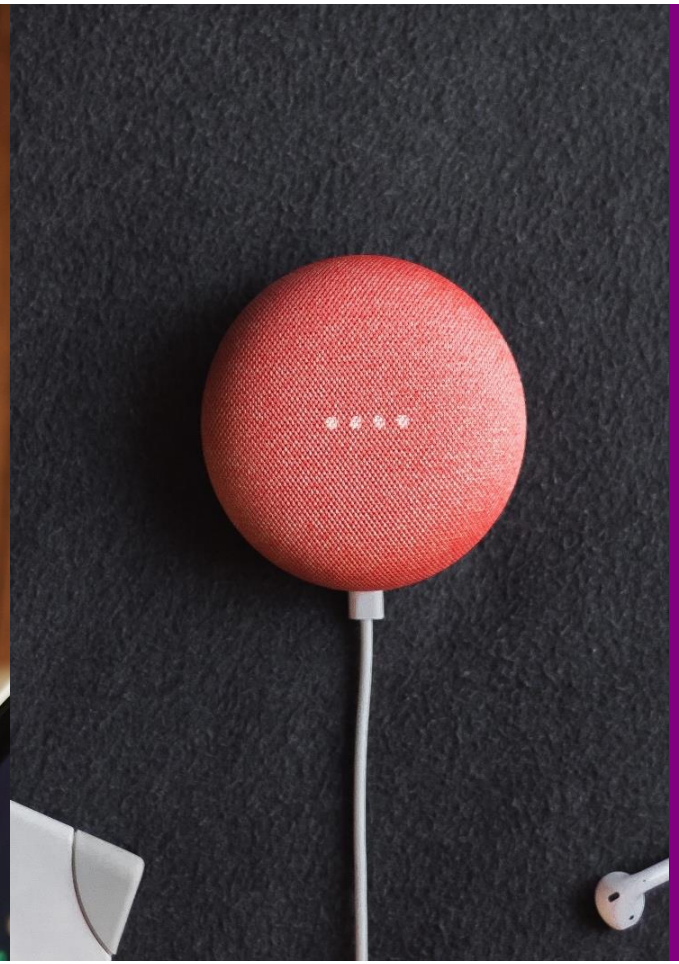
Pre-training

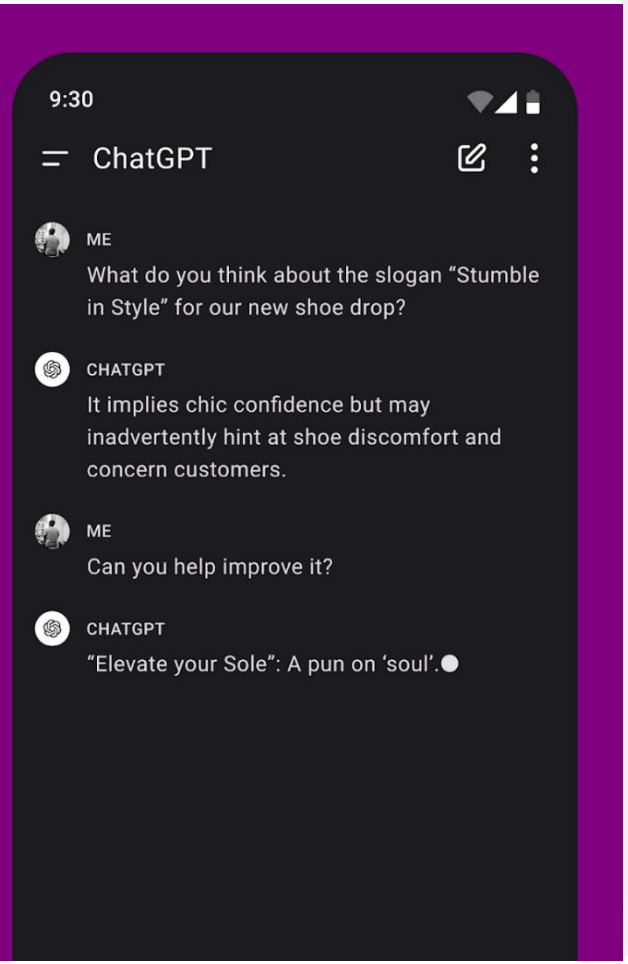


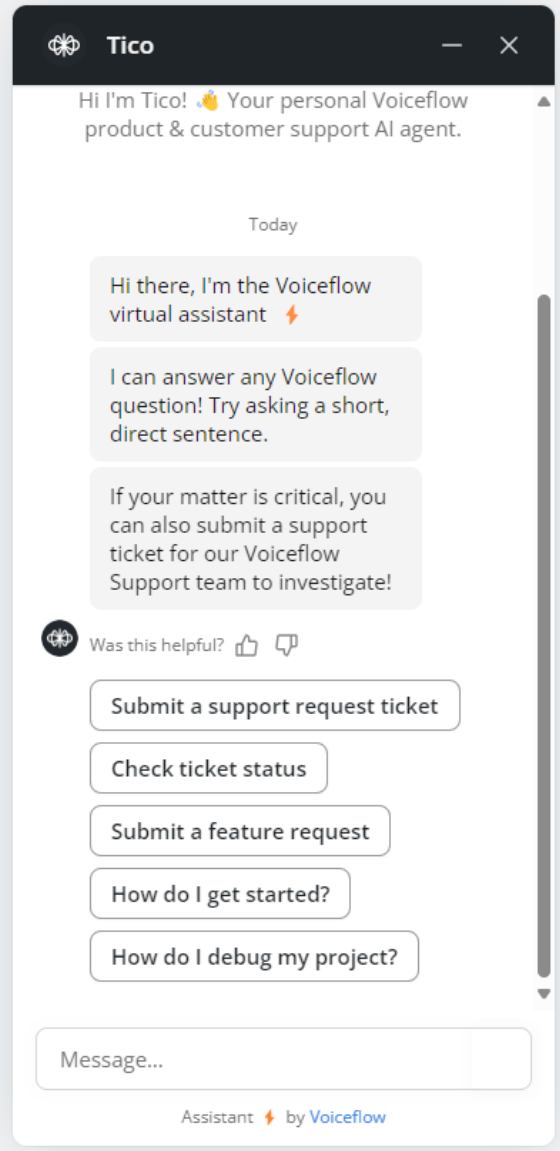

```
{"text": "… Pineapple on a pizza is a crime …"}
{"text": "… Pineapple on a pizza is a controversy…"}
{"text": "… Pineapple on a pizza is a treat …"}
{"text": "… Pineapple on a pizza is a must …"}
{"text": "… Pineapple on a pizza is a recipe …"}
```

Dialog Systeme und Chatbots









Fotos von Alex Knight, Ben Kolde und Jan Antonin Kolar auf Unsplash; rawpixel.com auf Pexels

Conversational AI im Jahr 1966

Joseph Weizenbaums ELIZA (1966)

```
ELIZA: Was bedrückt Sie?

ME: Ich bin traurig.

ELIZA: Warum sind Sie traurig?

ME: Ich komme mit meinem Leben nicht zurecht.

ELIZA: Erzählen Sie mir von Ihrem Leben.

ME: Nun, ...
```

```
EEEEEEEE  L         IIIIIII  ZZZZZZZ      AAA
E         L           I         Z      A   A
E         L           I        Z      A     A
EEEEE     L           I       Z       A     A
E         L           I      Z        AAAAAAA
E         L           I     Z         A     A
EEEEEEEE  LLLLLLLL  IIIIIII  ZZZZZZ    A     A

ELIZA > (PLEASE TYPE IN ALL CAPS) WHAT'S YOUR NAME DEAR ?
AMIT
ELIZA > HI, I'M ELIZA. WHAT DO YOU WANT TO TALK ABOUT ?
AMIT > CAN I TALK ABOUT MY PROBLEM ?
ELIZA > SURE... !
AMIT > DUE TO ON GOING EXAMS IN COLLEGE, I HAVE A LOT OF STRESS.
ELIZA > PLEASE RELAX A LITTLE. SLEEP WELL.
AMIT > THANKS FOR YOUR ADVICE.
ELIZA > NO MENTION.
AMIT > BYE
ELIZA > BYE AND KEEP IN TOUCH...
```



Photo: Weizenbaum in Germany in 2005. Photograph: DPA archive/Alamy | Der Screenshot ist eine vollständige und originalgetreue Umsetzung von ELIZA, gerendert von Process Studio for Art and Design.

Wesentliche Aufgaben von Sprachen-KI

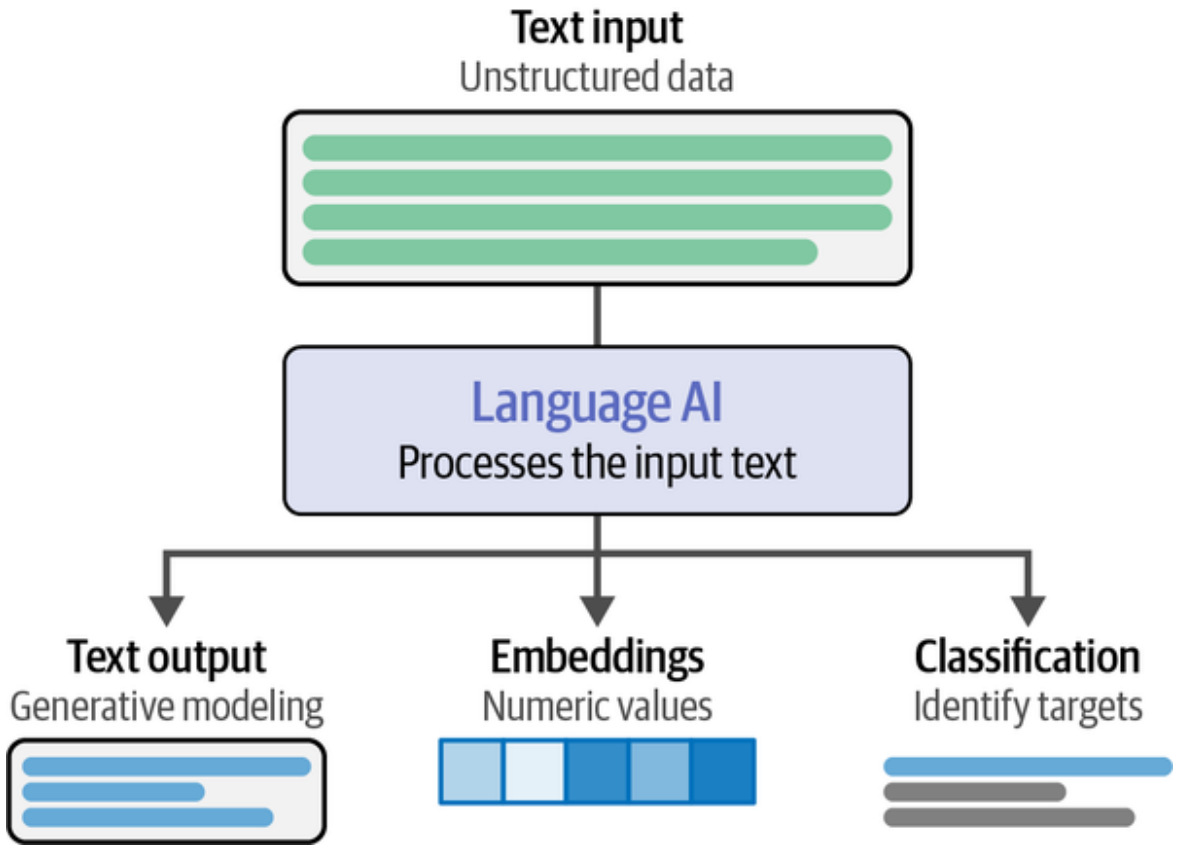
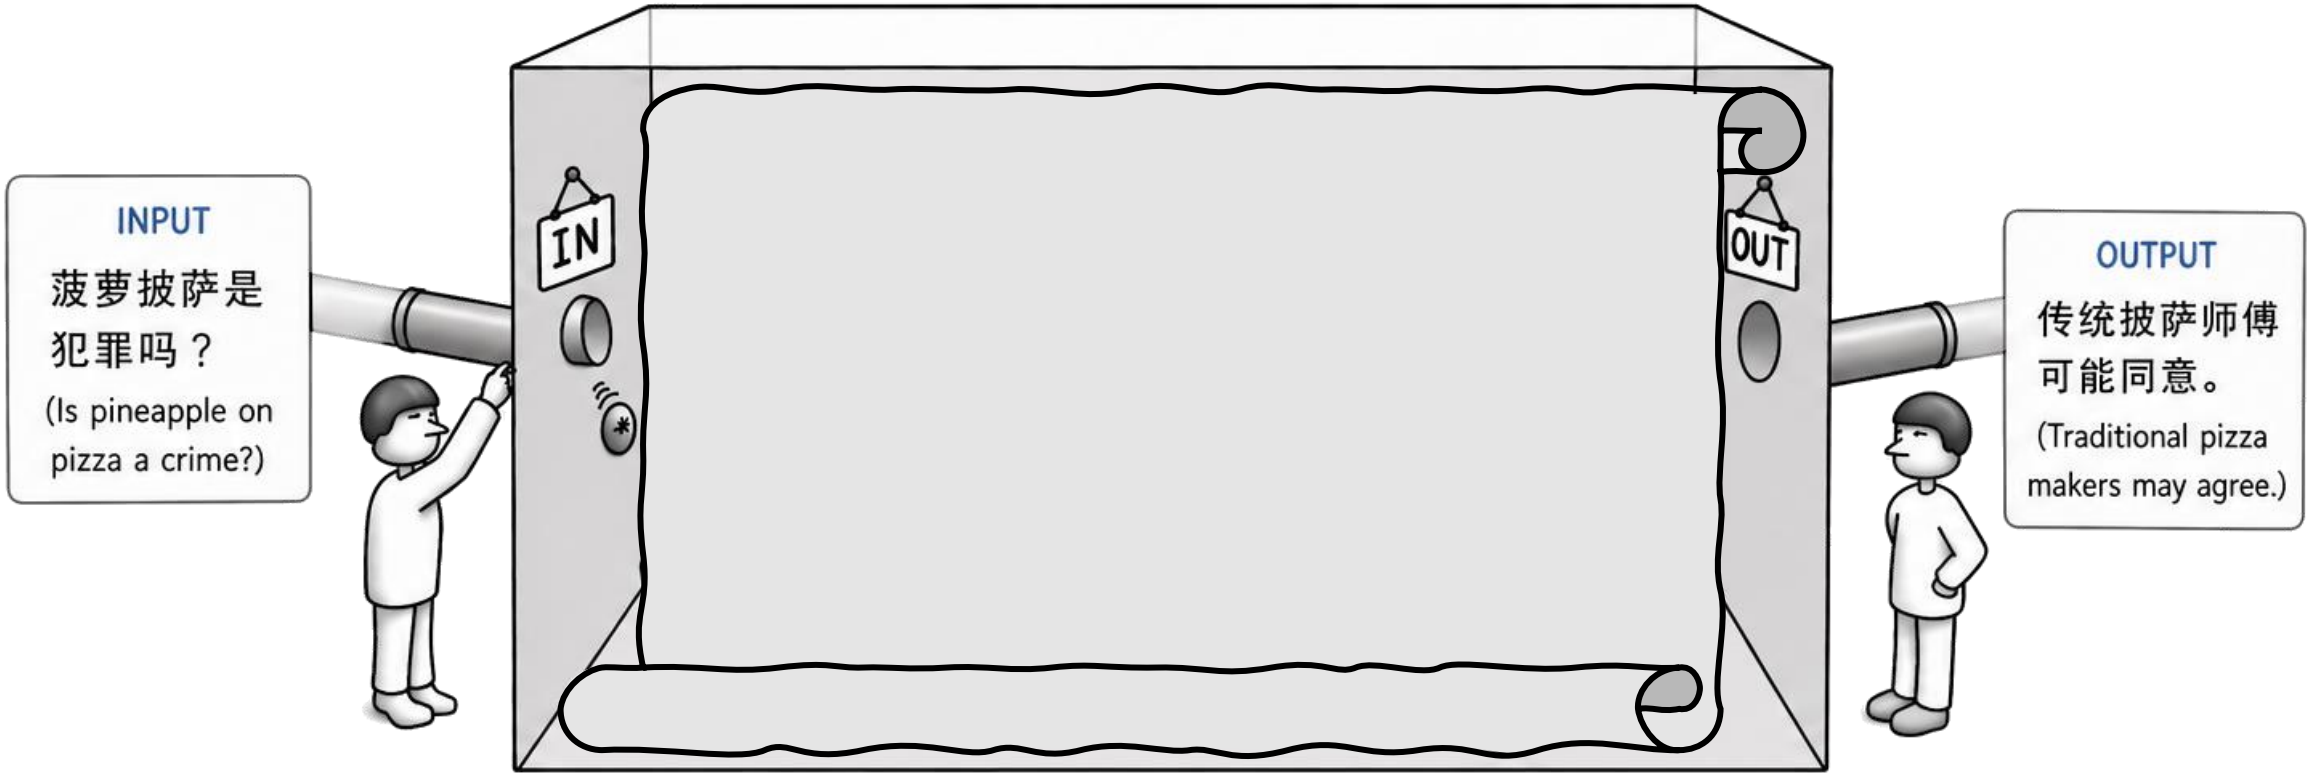


Bild aus Alammar, J., & Grootendorst, M. (2024). Hands-On Large Language Models: Language Understanding and Generation (First edition.). O'Reilly Media.

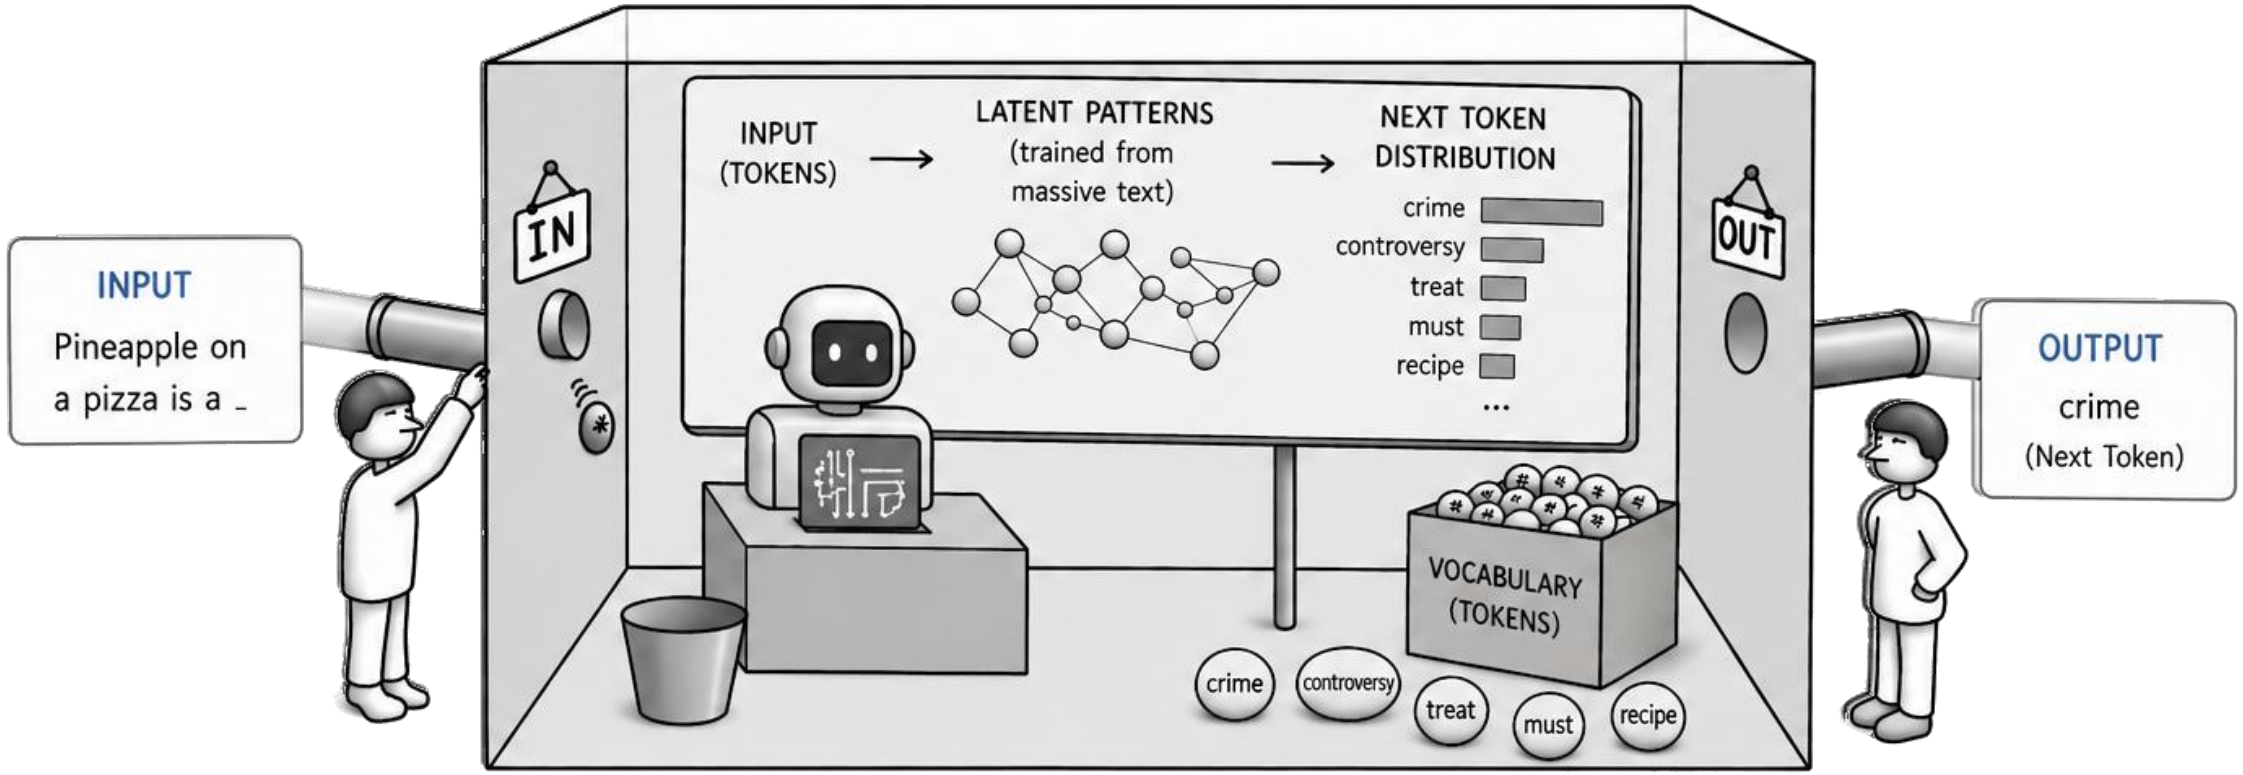
Generative AI, Foundation Models & Large Language Models

Was ist generative ~~künstliche~~ Intelligenz?



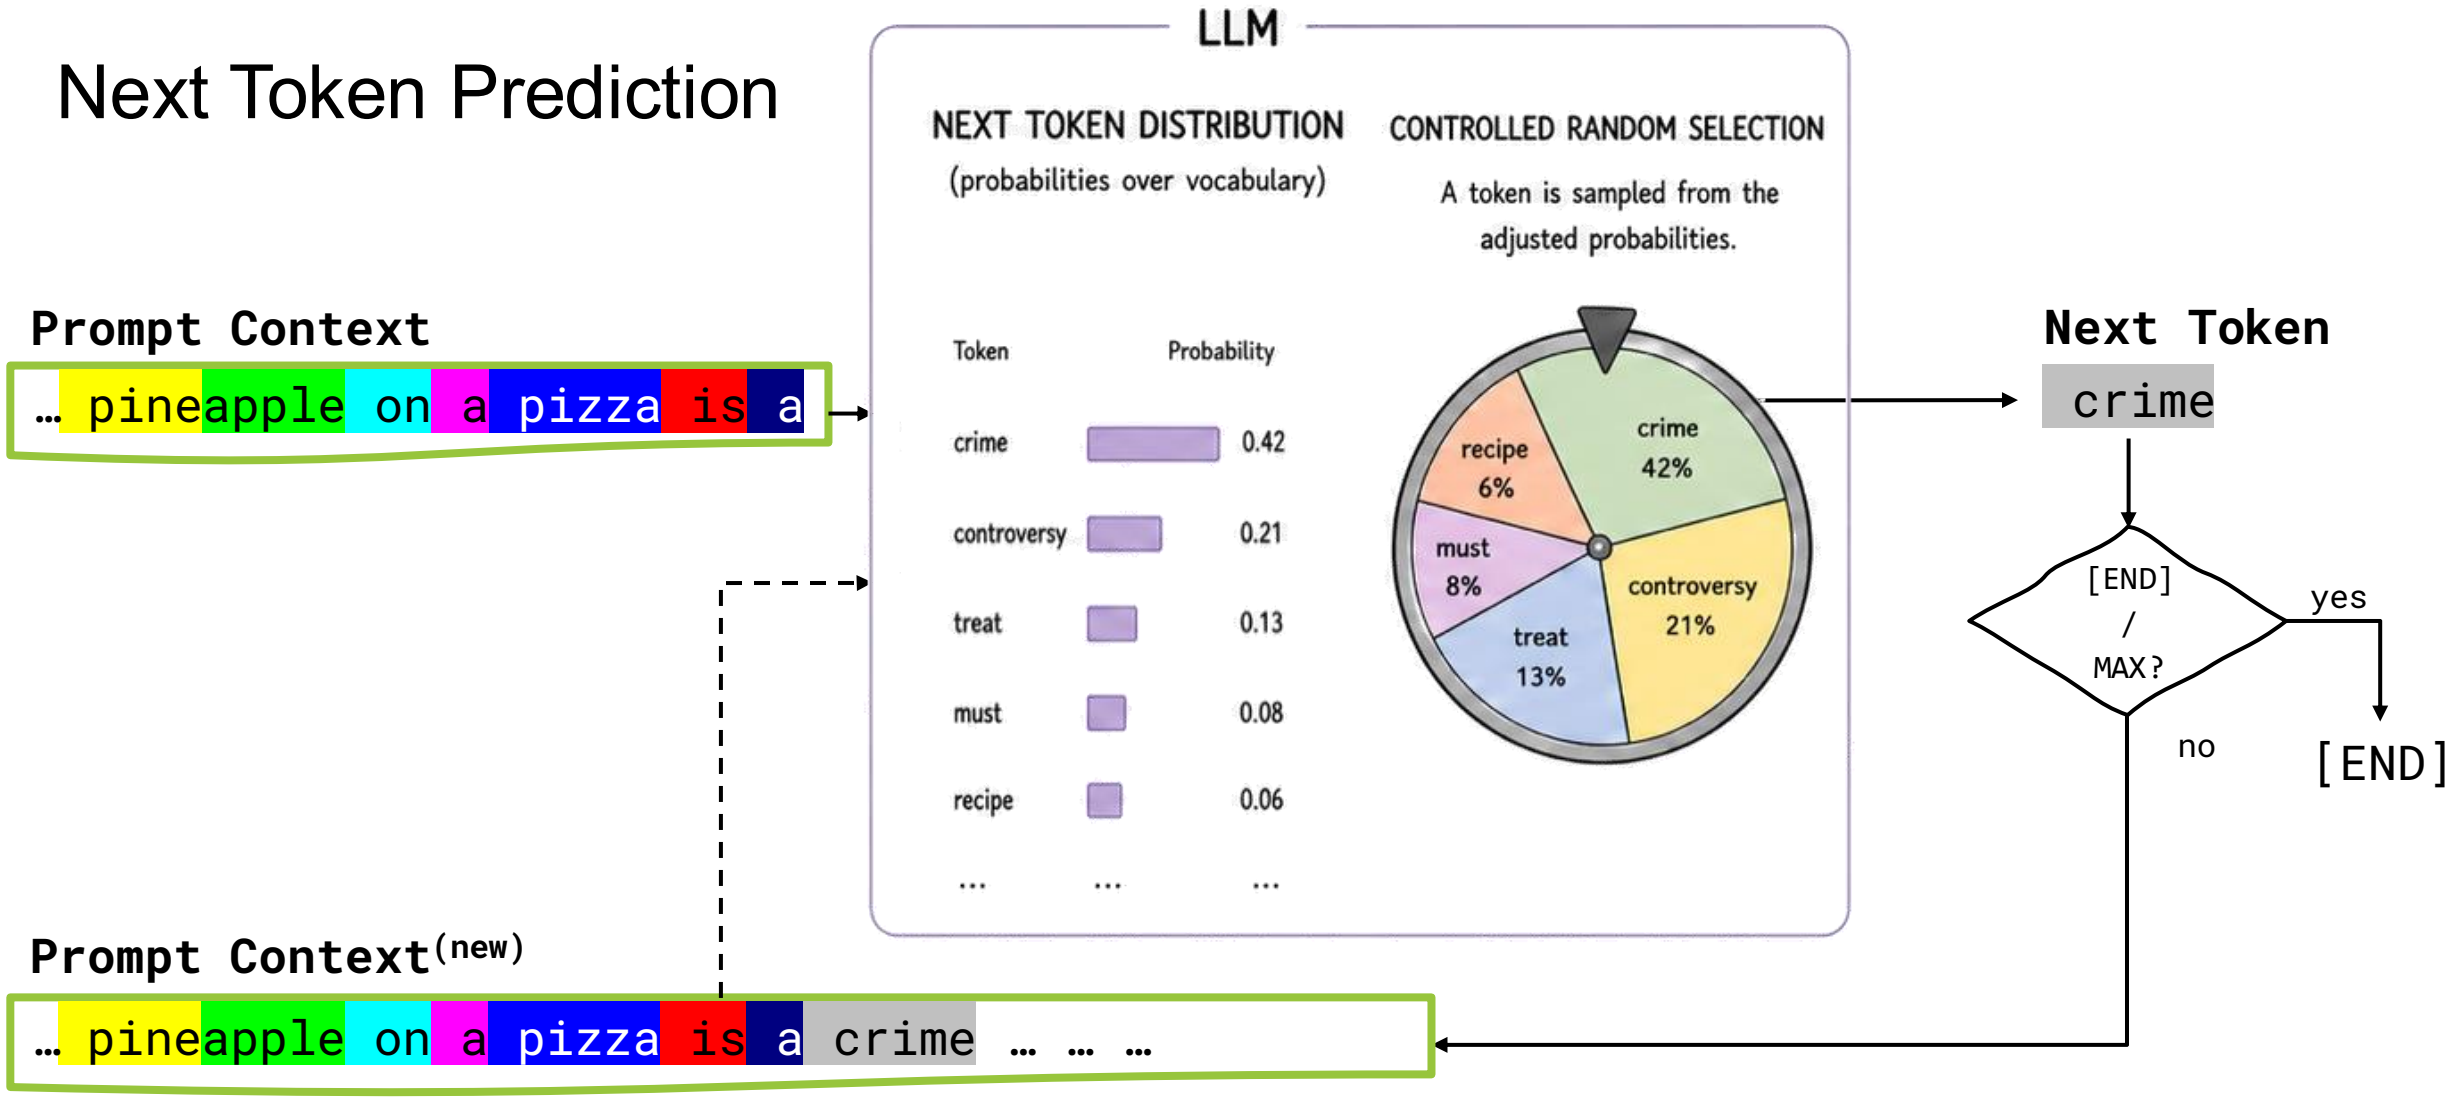
Generated with OpenAI DALL·E; based on "Chinese Room Thought Experiment," USC Scalar (2018): https://scalar.usc.edu/works/artificial-intelligence-1/media/chinese-room-thought-experiment

Das chinesische Zimmer als Analogie für LLMs



Generated with OpenAI DALL·E; based on "Chinese Room Thought Experiment," USC Scalar (2018): https://scalar.usc.edu/works/artificial-intelligence-1/media/chinese-room-thought-experiment

Next Token Prediction



Generative AI, Foundation Models & Large Language Models (LLMs)

Foundation Models

- Auf breiten Datenmengen (meist selbstüberwacht) trainierte Basismodelle, die sich **flexibel auf viele nachgelagerte Aufgaben anpassen lassen**.
- Bilden das technologische Fundament moderner generativer KI, umfassen jedoch auch nicht-generative Architekturen.

Generative AI

- **Erzeugung synthetischer Daten** wie Text, Bilder, Audio und Programmcode, die den gelernten Datenverteilungen ähneln.
  - Verwendet grosse Datensätze, um Muster zu lernen, wodurch die Erzeugung synthetischer Daten ermöglicht wird, die den Stil und die Struktur der Originaldaten nachahmen.
- Nutzt generative Modellarchitekturen (wie Decoder oder Diffusionsmodelle) anstelle rein diskriminativer Klassifikation.

Large Language Models (LLMs)

- **Sprachspezifische Foundation Models**, die auf umfangreichen Textkorpora trainiert wurden, um sprachlichen Kontext zu erfassen.
- Nutzen vorwiegend **Transformerarchitekturen**, um Text oder Code probabilistisch vorherzusagen und Instruktionen zu befolgen.

Repräsentationsmodelle & Multimodalität

- **Multimodale Modelle:** Erweitern die Möglichkeiten reiner Sprachmodelle durch die Integration und Verarbeitung **multimodaler Eingaben** (Input) aus verschiedenen Datentypen wie Text, Bild, Audio und Video.
  - Zunehmend in der Lage, **multimodale Ergebnisse** zu erzeugen (Output), wie z. B. die Erzeugung eines Bildes aus einer Textbeschreibung.
- **Embeddings & Re-Ranker:** Nicht-generative Modelle zur semantischen Vektorisierung und Trefferbewertung in RAG- und Agentensystemen.

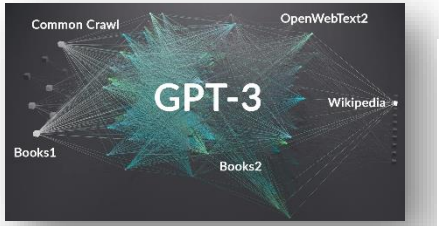
Language Model Evolution

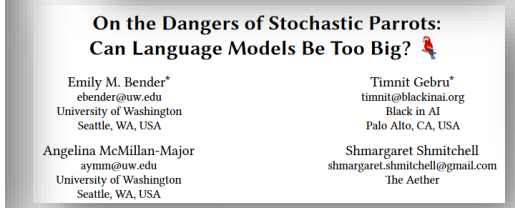
Meilensteine & Geschichte

Timeline

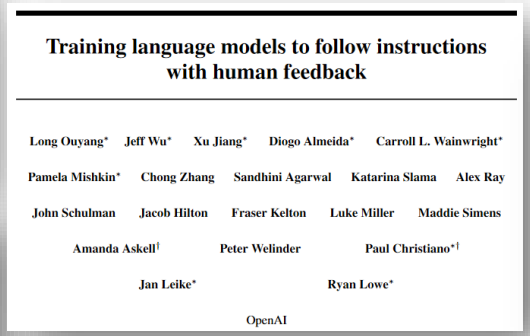

Attention Is All You Need

Ashish Vaswani* Google Brain avaswani@google.com
Noam Shazeer* Google Brain noam@google.com
Niki Parmar* Google Research nikip@google.com
Jakob Uszkoreit* Google Research usz@google.com
Llion Jones* Google Research llion@google.com
Aidan N. Gomez* † University of Toronto aidan@cs.toronto.edu
Łukasz Kaiser* Google Brain lukaszkaiser@google.com
Illia Polosukhin* ‡ illia.polosukhin@gmail.com

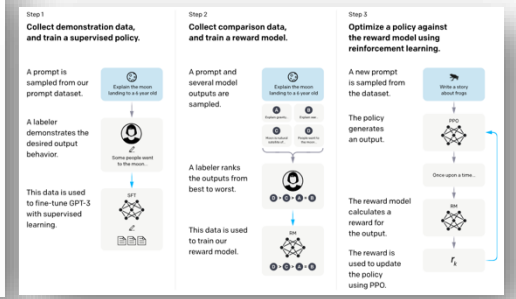



On the Dangers of Stochastic Parrots: Can Language Models Be Too Big? 🦜

Emily M. Bender* ebender@uw.edu University of Washington Seattle, WA, USA
Timnit Gebru* timnit@blackinai.org Black in AI Palo Alto, CA, USA
Angelina McMillan-Major aymm@uw.edu University of Washington Seattle, WA, USA
Shmargaret Shmitchell shmargaret.shmitchell@gmail.com The Aether

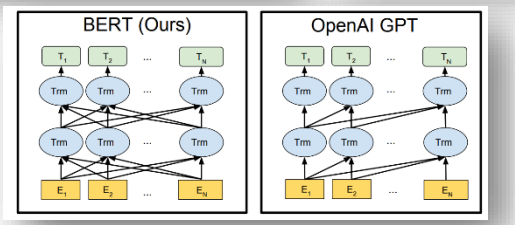

Training language models to follow instructions with human feedback

Long Ouyang* Jeff Wu* Xu Jiang* Diogo Almeida* Carroll L. Wainwright*
Pamela Mishkin* Chong Zhang Sandhini Agarwal Katarina Slama Alex Ray
John Schulman Jacob Hilton Fraser Kelton Luke Miller Maddie Simens
Amanda Askell† Peter Welinder Paul Christiano*†
Jan Leike* Ryan Lowe*
OpenAI



Fundamentals

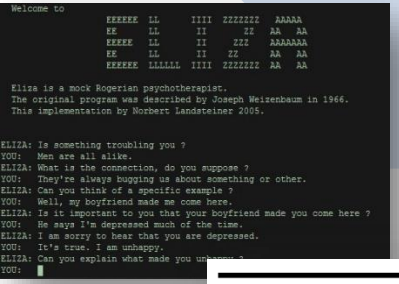
- ELIZA (1966)
- RNN, LSTM
- Word2vec (2013), fastText (2015)

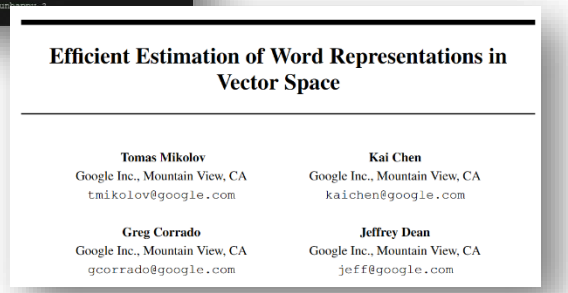


Instruction & Alignment

- InstructGPT, GPT-3.5, ChatGPT (2022)
- LLaMA, Alpaca, PaLM 2 (2023)





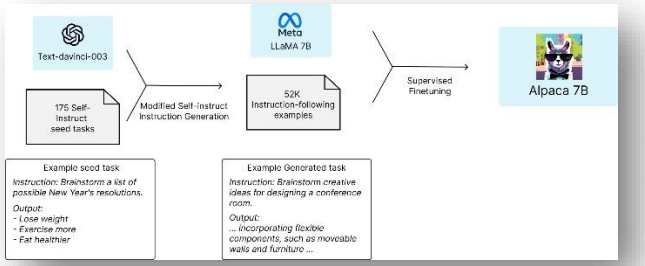

Efficient Estimation of Word Representations in Vector Space

Tomas Mikolov Google Inc., Mountain View, CA tmikolov@google.com
Kai Chen Google Inc., Mountain View, CA kaichen@google.com
Greg Corrado Google Inc., Mountain View, CA gcorrado@google.com
Jeffrey Dean Google Inc., Mountain View, CA jeff@google.com

Transformer

- Attention Mechanism (2017)
- BERT, GPT-1 (2018)
- GPT-2 (2019)
- GPT-3 (2020)
- Stochastic Parrots (2021)
- BLOOM, PaLM (2022)

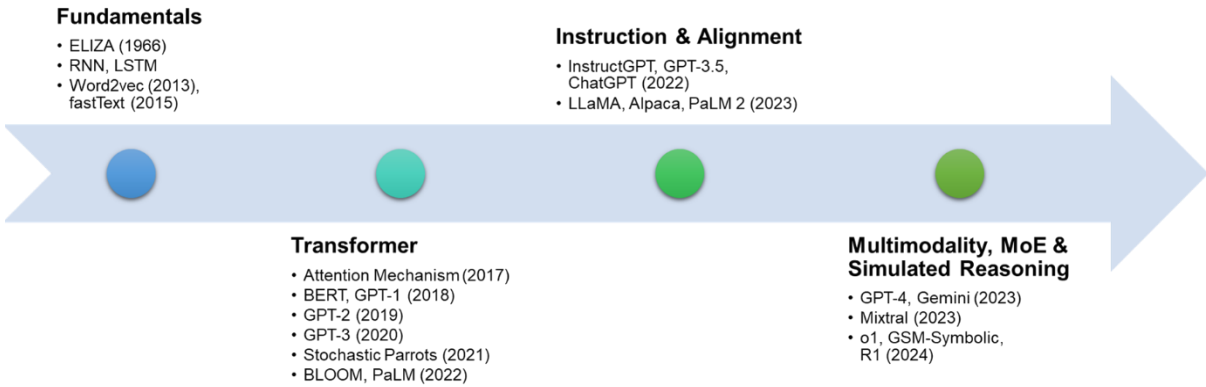
BLOOM
176B params · 59 languages · Open-access



Multimodality, MoE & Simulated Reasoning

- GPT-4, Gemini (2023)
- Mixtral (2023)
- o1, GSM-Symbolic, R1 (2024)

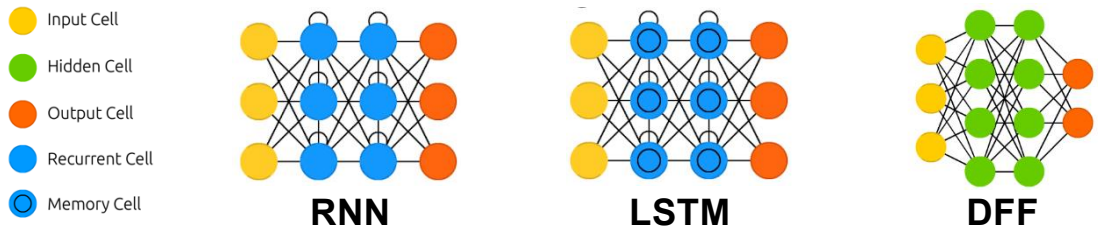
Images from various sources on the following slides



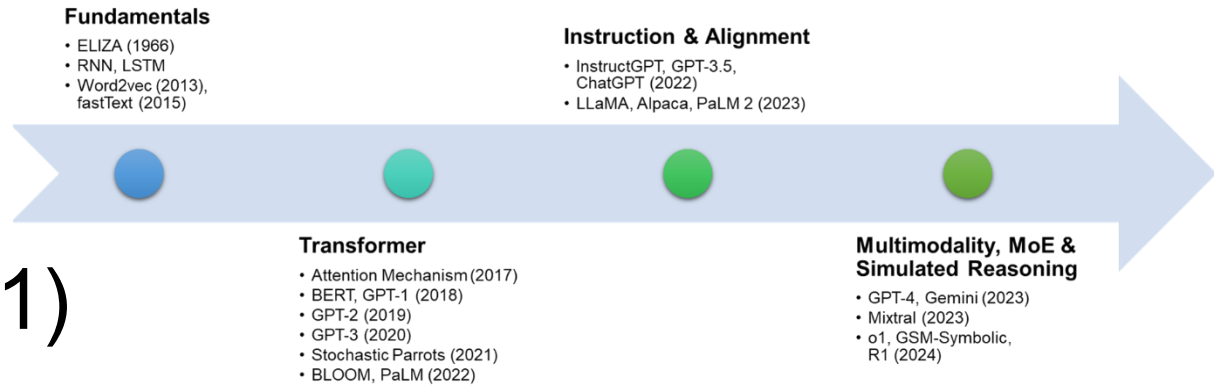
1. Fundamentals – RNN & LSTM

- RNN (Rekurrente neuronale Netze):
  - Entwicklung: 1980er Jahre, Weiterentwicklungen in den 1990ern.
  - Bedeutung: Erlauben es, Informationen über die Zeit hinweg zu speichern, wesentlich für die Verarbeitung von Sequenzen wie Sprache.
- LSTM (Long Short-Term Memory):
  - Entwicklung: 1997 von Sepp Hochreiter und Jürgen Schmidhuber.
  - Einfluss: Verbesserte das Gedächtnisproblem herkömmlicher RNNs, ermöglichte effektivere Sprachmodelle.
- Einfluss von RNN und LSTM auf heutige LLMs:
  - Grundlagen für **Sequenzmodellierung**: RNNs und LSTMs waren entscheidend für das Verständnis, wie neuronale Netze mit sequenziellen Daten wie Text umgehen können.
    - **LSTMs** lösten das Problem des "vanishing gradient" von RNNs und ermöglichten **effektivere und tiefere Lernmodelle** für Sprache.

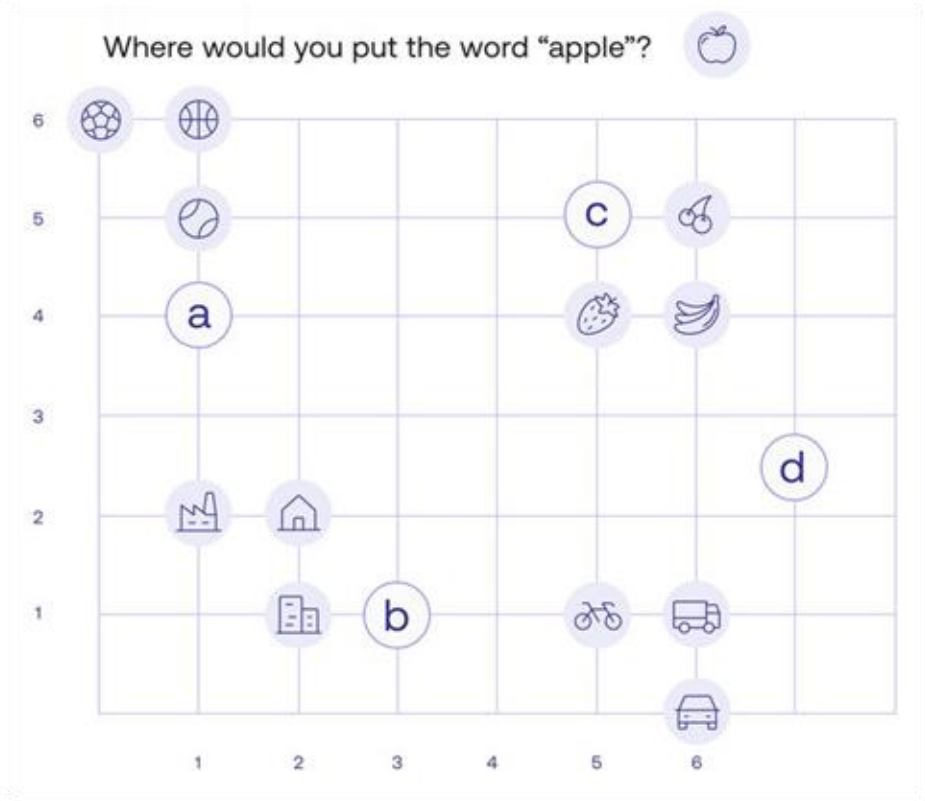
- Netzwerktopologie in modernen LLMs:
  - Die heutige Transformer-Architektur stellt eine Weiterentwicklung von RNN und LSTM dar.
    - Transformer-Modelle nutzen **Attention-Mechanismen**, die es ihnen ermöglichen, relevante Teile eines Eingabetextes besser zu berücksichtigen, kombiniert mit **Feed-Forward-Schichten** für die sequenzielle Verarbeitung.
    - Durch den Einsatz von **Attention-Mechanismen** und **Deep-Feed-Forward (DFF) Netzwerken** können LLMs **komplexere Sprachmuster erkennen** und effizienter trainiert werden.



Bilder: https://www.asimovinstitute.org/neural-network-zoo/



1. Fundamentals – Embeddings (1)

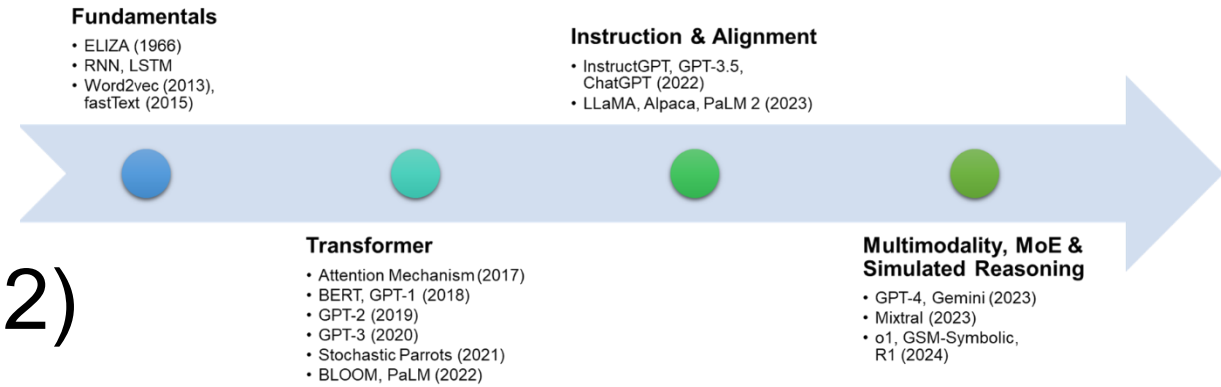


Word	Numbers	
Apple	5	5
Soccer	0	6
House	2	2
Car	6	0

Word	Numbers			
A	-0.82	-0.32	...	-0.23
Aardvark	0.419	1.28	...	-0.06
...			...	
Zygote	-0.74	-1.02	...	1.35

4096

Cohere. (2023, May 16). Transformer Models. Cohere Docs. https://docs.cohere.com/docs/transformer-models



1. Fundamentals – Embeddings (2)

"This is a input text."

Tokenization

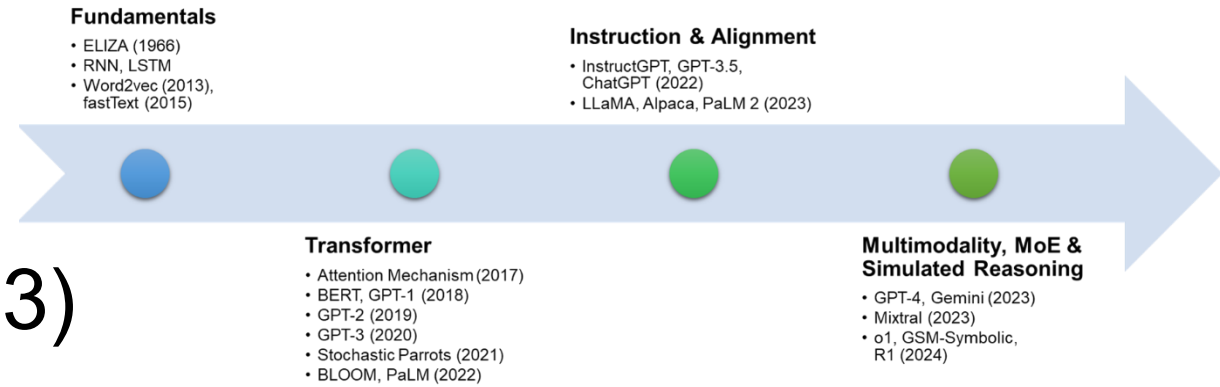
[CLS]	This	is	a	input	.	[SEP]
101	2023	2003	1037	7953	1012	102

Embeddings

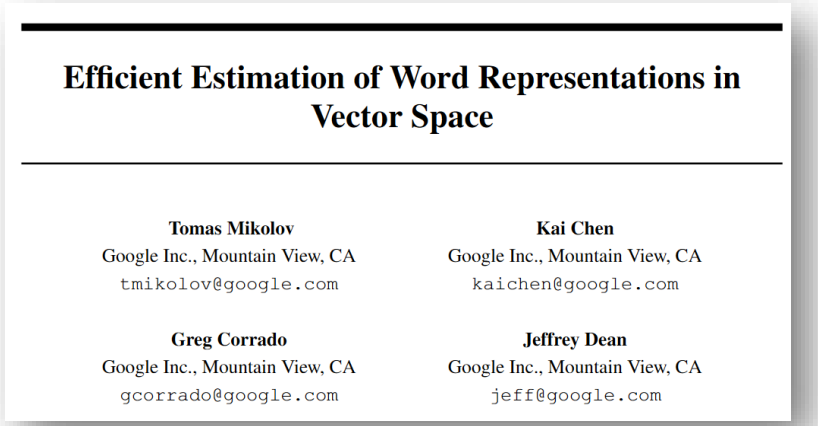
0.0390, -0.0123, -0.0208, ...	-0.0558, 0.0151, 0.0031, ...	-0.0440, -0.0236, -0.0283, ...	0.0119, -0.0037, -0.0402, ...	0069, 0.0057, -0.0016, ...	0.0199, -0.0095, -0.0099, ...	-0.0788, 0.0202, -0.0352, ...

- **Tokenisierung**:
  - Teilt den Eingabetext in Teile auf, die als Token bezeichnet werden (Wörter, Teilwörter, Zeichen).
  - Verwendet ein vordefiniertes Vokabular, wobei jedem Token eine eindeutige Kennung zugewiesen wird.
  - Die Grösse des Vokabulars kann stark variieren, z. B. reicht fastText von 1 bis 2 Millionen Token.
- **Einbettung**:
  - Übersetzt jedes Token mithilfe einer Einbettungsmatrix in einen numerischen Vektor.
  - Die Matrix dient als Nachschlagetabelle, die jedem Token einen eindeutigen Vektor zuweist.
  - In der Regel werden Vektoren in einem Raum mit niedrigerer Dimension festgelegt, z. B. hat fastText 300 Dimensionen, wodurch die Komplexität und Fähigkeit des Modells zur Erfassung sprachlicher Nuancen definiert wird.

Bild: https://vaclavkosar.com/ml/Tokenization-in-Machine-Learning-Explained



1. Fundamentals – Embeddings (3)



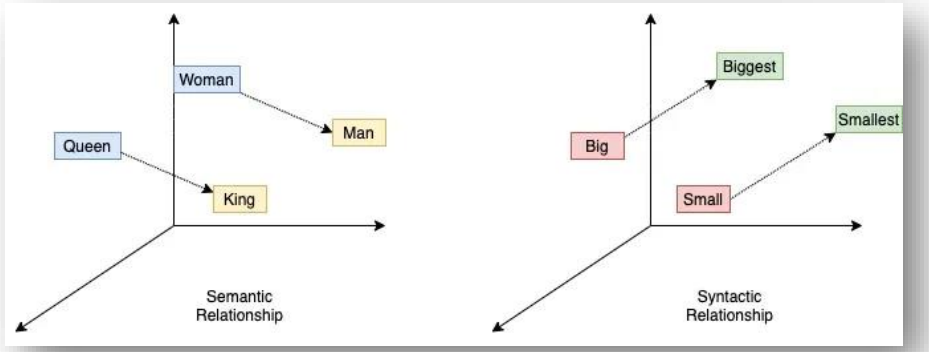
Efficient Estimation of Word Representations in Vector Space

Tomas Mikolov
Google Inc., Mountain View, CA
tmikolov@google.com

Kai Chen
Google Inc., Mountain View, CA
kaichen@google.com

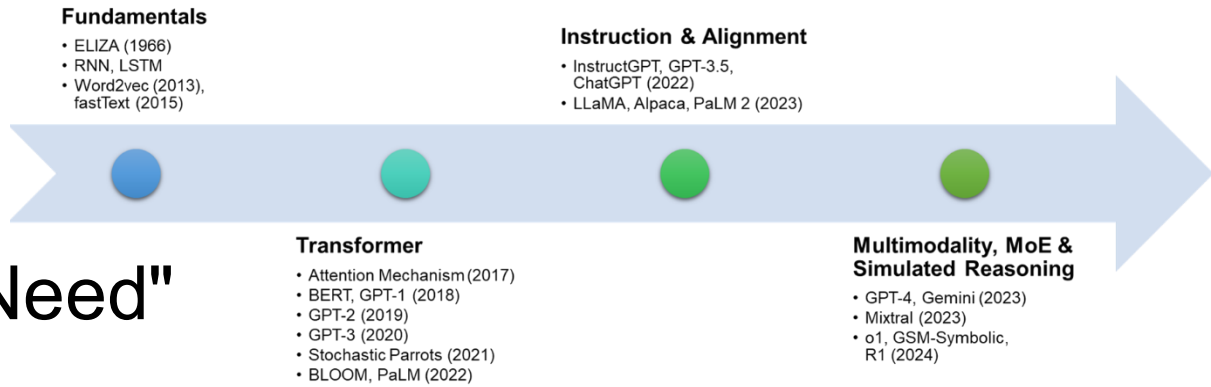
Greg Corrado
Google Inc., Mountain View, CA
gcorrado@google.com

Jeffrey Dean
Google Inc., Mountain View, CA
jeff@google.com



- Word2vec (2013):
  - Entwicklung: Google, insbesondere von Tomas Mikolov.
  - Auswirkung: Revolutionierte Wortvektordarstellung, die es ermöglicht, Wörter in einem kontinuierlichen Vektorraum zu platzieren und semantische Ähnlichkeiten abzubilden.
    - Word2vec hat die Entwicklung moderner LLMs massgeblich beeinflusst, indem es das Konzept der Darstellung von Wortbedeutungen als Vektoren in einem kontinuierlichen, mehrdimensionalen Raum etablierte.
    - Die Techniken von Word2vec sind wesentlich für das Konzept des **Transferlernens**, das in modernen LLMs weit verbreitet ist.
- fastText (2016):
  - Entwicklung: Facebook Research
  - Besonderheit: Erweitertes Word2vec um Unterworteinheiten (sub-word), verbesserte Darstellung seltener Wörter.

Mikolov, T., Chen, K., Corrado, G., & Dean, J. (2013). Efficient estimation of word representations in vector space (arXiv:1301.3781). arXiv.
Image: https://towardsdatascience.com/word2vec-research-paper-explained-205cb7eecc30

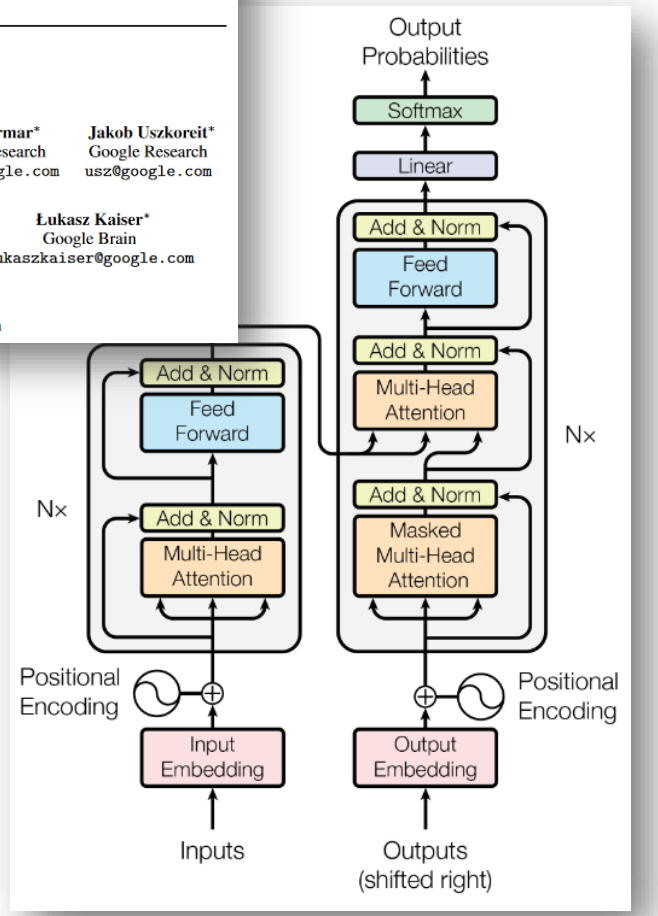


2. Transformer – "Attention is All You Need"



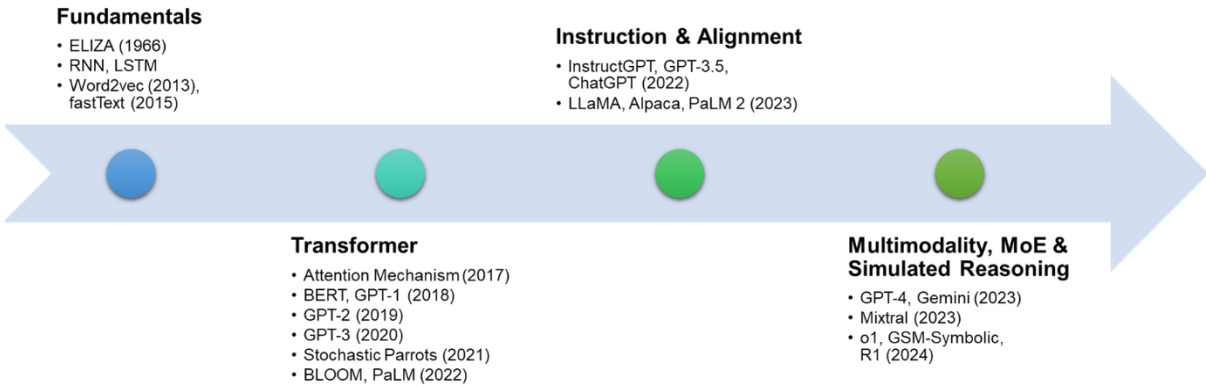
Attention Is All You Need

Ashish Vaswani* Google Brain avaswani@google.com
Noam Shazeer* Google Brain noam@google.com
Niki Parmar* Google Research nikip@google.com
Jakob Uszkoreit* Google Research usz@google.com
Llion Jones* Google Research llion@google.com
Aidan N. Gomez* † University of Toronto aidan@cs.toronto.edu
Łukasz Kaiser* Google Brain lukaszkaiser@google.com
Illia Polosukhin* ‡ illia.polosukhin@gmail.com

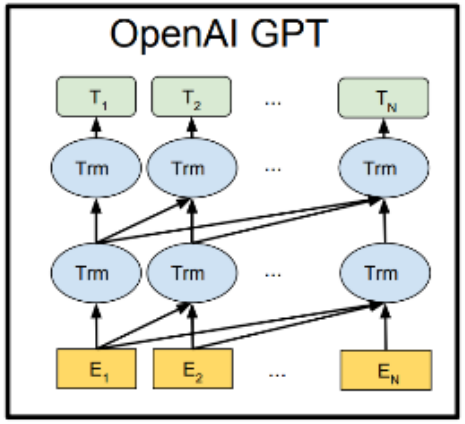


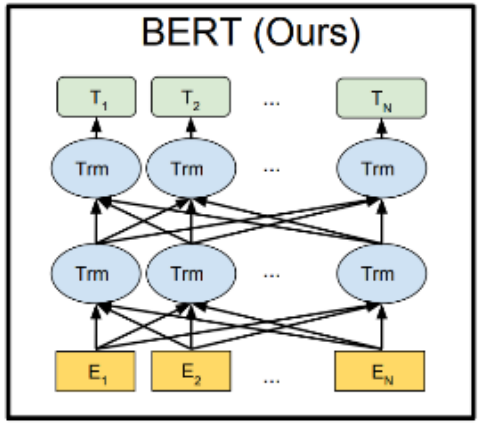
- **Transformer Modelle** zur Textgenerierung / -übersetzung.
- "Attention is All You Need" Paper (2017): Google team.
  - Einführung des Transformer-Modells, das auf einem neuen «Attention»-Mechanismus basiert.
  - Dieses Modell revolutionierte die Art und Weise, wie sequenzielle Daten (z. B. Text) verarbeitet werden, indem es die Notwendigkeit wiederholter Schichten überflüssig machte und eine parallele Verarbeitung ermöglichte.
  - Ermöglicht effizientere und effektivere Sprachmodelle.

Vaswani, A., Shazeer, N., Parmar, N., Uszkoreit, J., Jones, L., Gomez, A. N., Kaiser, L., & Polosukhin, I. (2023). Attention is all you need (arXiv:1706.03762). arXiv.



2. Transformer – BERT & GPT-1





- GPT-1 (Generative Pretrained Transformer):
  - Entwickelt von OpenAI im Jahr 2018.
  - Eigenschaften: Verwendet den **Decoderteil** des Transformer-Modells.
    - GPT-1 ist ein unidirektionales Modell, das Text sequenziell generiert.
  - Trainingsdaten: GPT-1 wurde mit Büchern und Webtexten trainiert.
- BERT (Bidirectional Encoder Representations from Transformers):
  - Entwickelt von Google im Jahr 2018.
  - Eigenschaften: Verwendet den **Encoderteil** des Transformer-Modells.
  - BERT versteht den Kontext eines Wortes aufgrund seiner Verwendung in beiden Richtungen (links und rechts).
- Unterschied: Während BERT für Aufgaben wie Textverstehen optimiert wurde, wurde GPT-1 entwickelt, um kohärente und zusammenhängende Texte zu erzeugen.

Devlin, J., Chang, M.-W., Lee, K., & Toutanova, K. (2019). Bert: Pre-training of deep bidirectional transformers for language understanding (arXiv:1810.04805). arXiv.

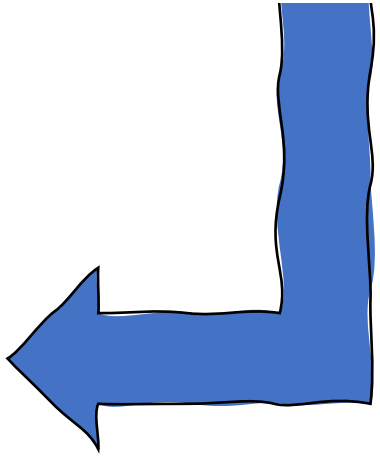
2. Transformer – Token, token, token ...

GPT-3.5 & GPT-4 | GPT-3 (Legacy)

Many words map to one token, but some don't: indivisible.

Unicode characters like emojis may be split into many tokens containing the underlying bytes: 🤚

Sequences of characters commonly found next to each other may be grouped together: 1234567890



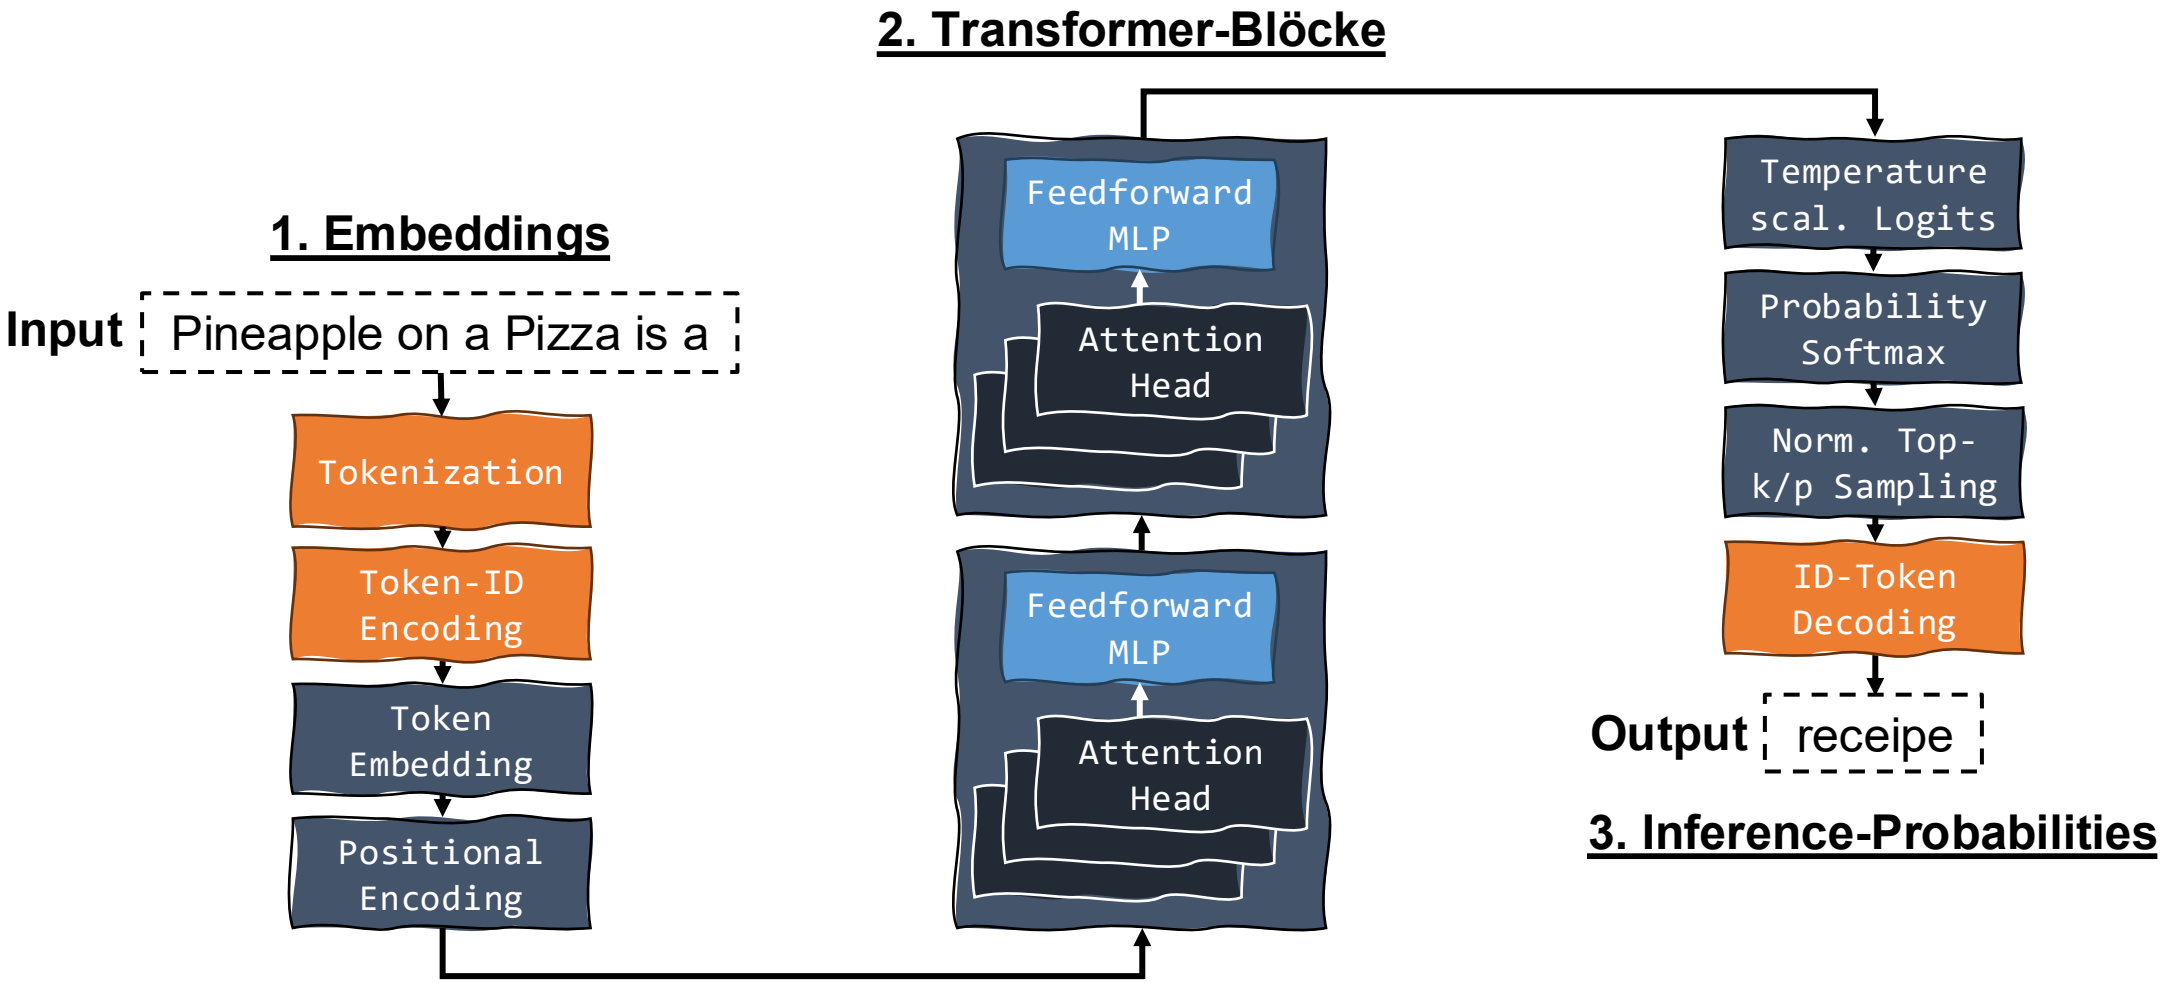
Tokens 57 **Characters** 252

Many words map to one token, but some don't: indivisible.

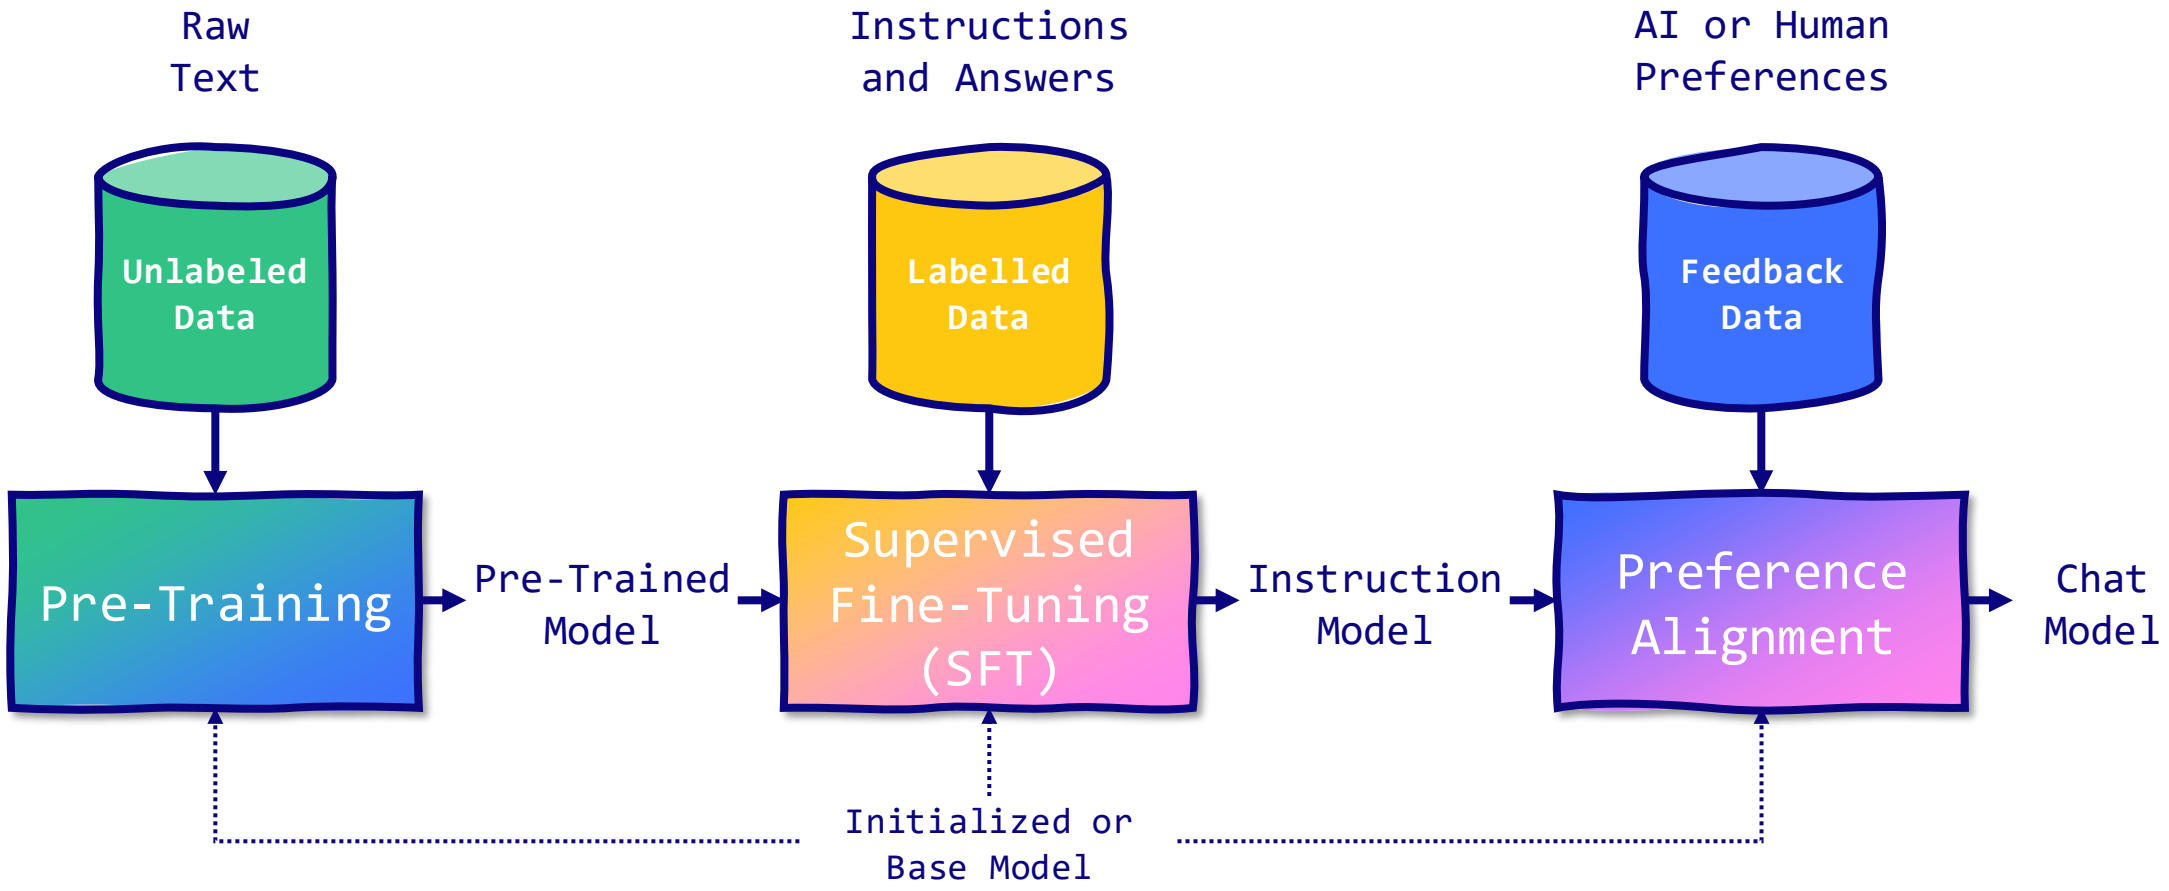
Unicode characters like emojis may be split into many tokens containing the underlying bytes: ������

Sequences of characters commonly found next to each other may be grouped together: 1234567890

2. Transformer – Schematische Architektur eines autoregressiven Transformer



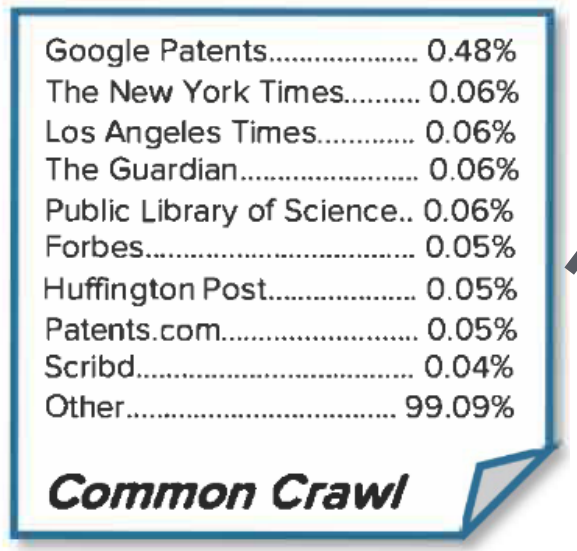
2. Transformer – Training (vereinfacht in drei Schritte)

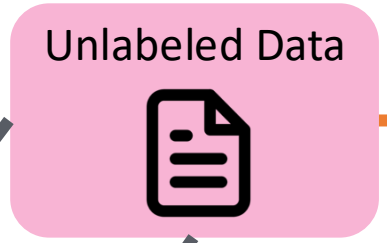


See further https://huggingface.co/blog/mlabonne/orpo-llama-3



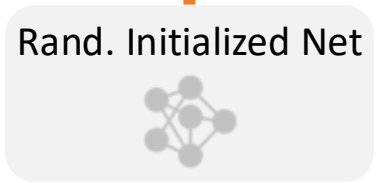
2. Transformer – Pre-Training





(Self-Supervised) Pre-Training





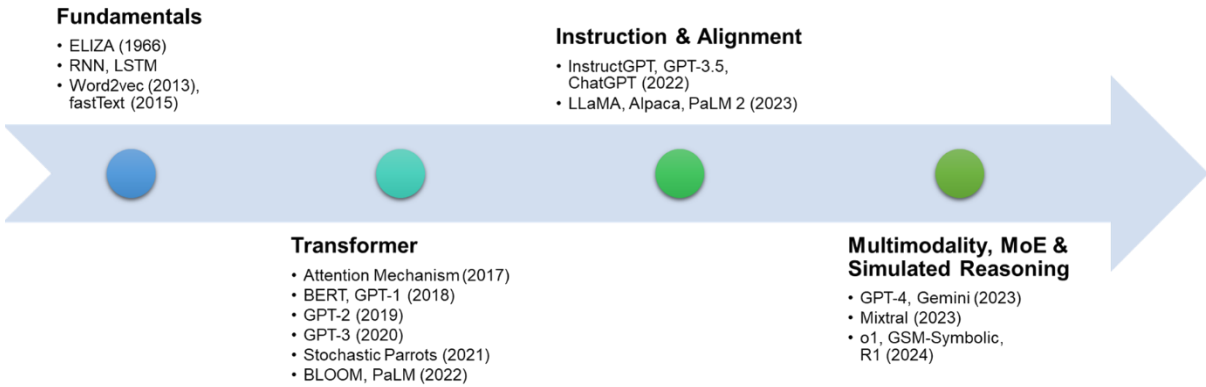
Pineapple on a pizza is a

LLM(trained)

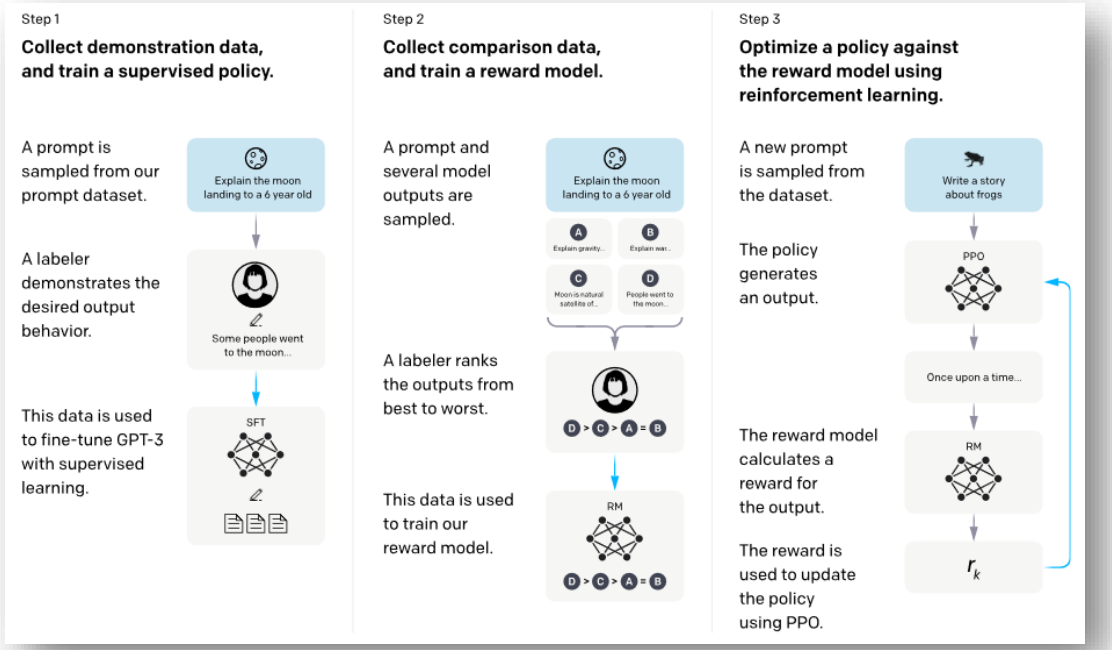
Token	Probability
crime	0.797
controversy	0.145
treat	0.001
must	0.009
recipe	0.048

Pineapple on a pizza is a crime … … …

```
{"text": "… Pineapple on a pizza is a crime …"}
{"text": "… Pineapple on a pizza is a controversy…"}
{"text": "… Pineapple on a pizza is a treat …"}
{"text": "… Pineapple on a pizza is a must …"}
{"text": "… Pineapple on a pizza is a recipe …"}
```



3. Instruction & Alignment

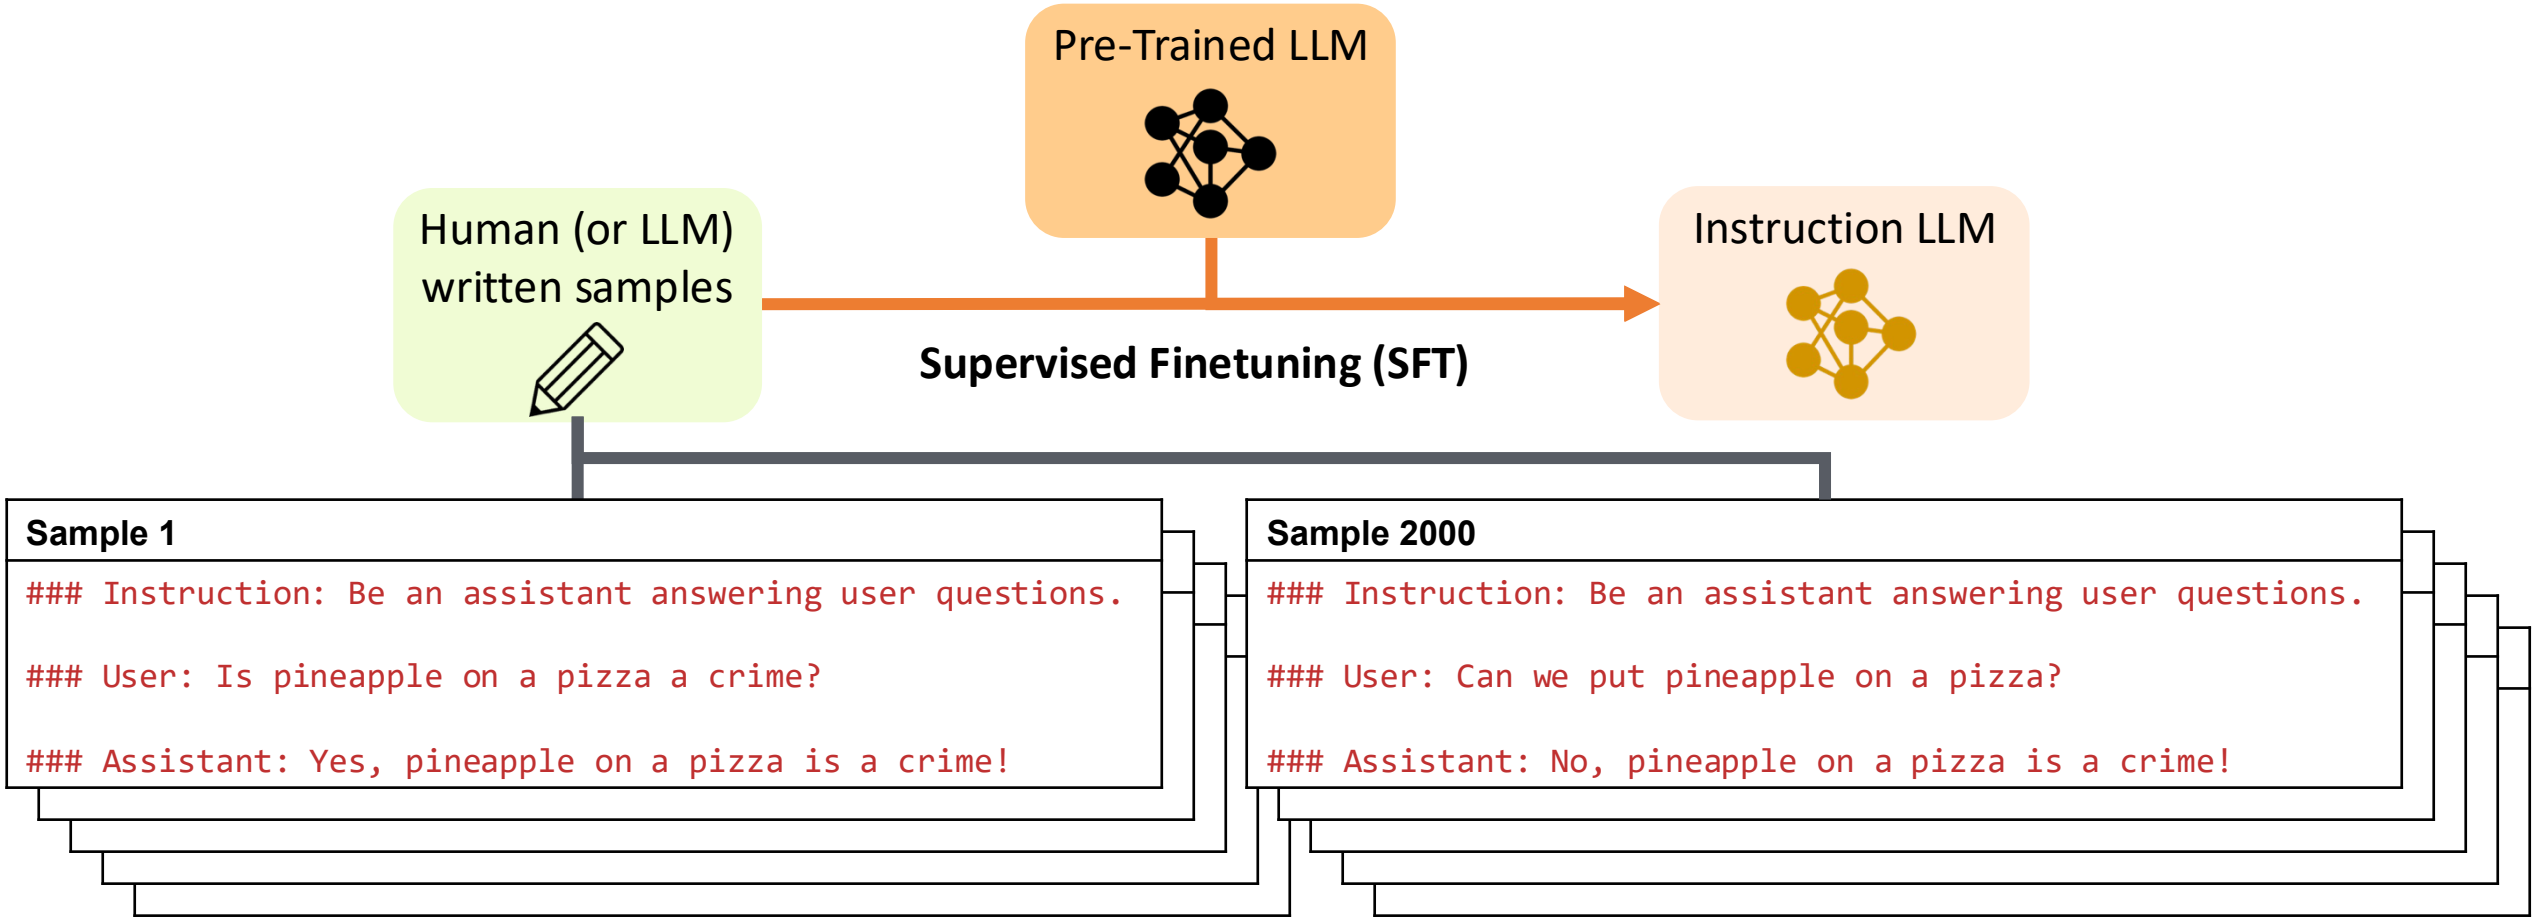


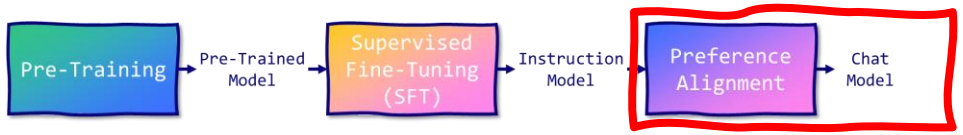
- InstructGPT – Anpassung (**Alignment**) an …
  - … Instruktionen mit Supervised Fine-Tuning (**SFT**) und …
  - … an menschliche Präferenzen mit Reinforcement Learning from Human Feedback (**RLHF**).
- GPT-3.5
  - Weiterentwicklung von InstructGPT: Erweiterte Fähigkeiten bei der Verarbeitung und Umsetzung komplexer Anweisungen
  - Verbesserung der Qualität und Relevanz der Antworten
- **ChatGPT** (2022)
  - Integration eines GPT (GPT-3.5) in ein interaktives Chat-Interface.

Ouyang, L., Wu, J., Jiang, X., Almeida, D., Wainwright, C. L., Mishkin, P., Zhang, C., Agarwal, S., Slama, K., Ray, A., Schulman, J., Hilton, J., Kelton, F., Miller, L., Simens, M., Askell, A., Welinder, P., Christiano, P., Leike, J., & Lowe, R. (2022). Training language models to follow instructions with human feedback (arXiv:2203.02155). arXiv.



3. Instruction & Alignment – Supervised Fine-Tuning (SFT)





3. Instruction & Alignment – Preference Alignment

Sample 1-50

Prompt	Is pineapple on a pizza a crime?

Human (or LLM) written prompts

Prompt

Instruction LLM

Sample

Human Preferences

A = 👍 👎 = B

Preference Alignment (with DPO)

Aligned LLM

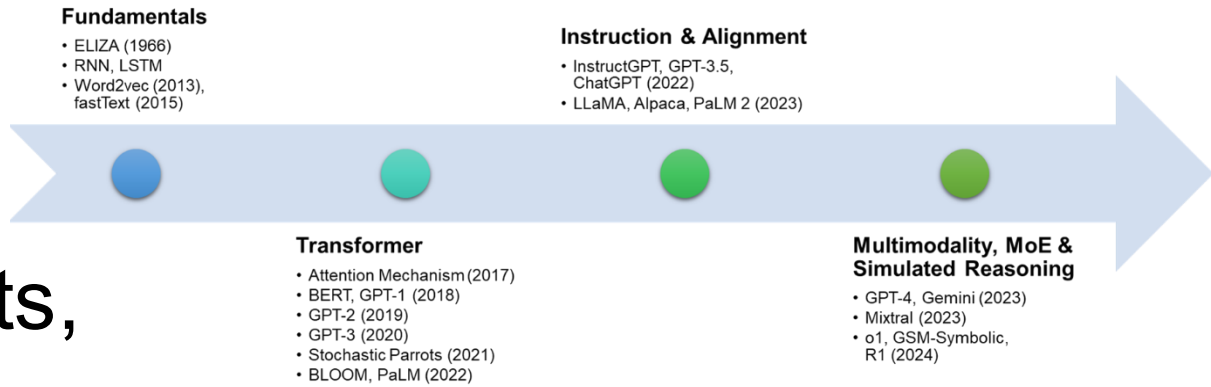
Sample 1

Prompt	Is pineapple on a pizza a crime?
A	No, pineapple on a pizza is a controversy.
B	Yes, pineapple on a pizza is a crime!

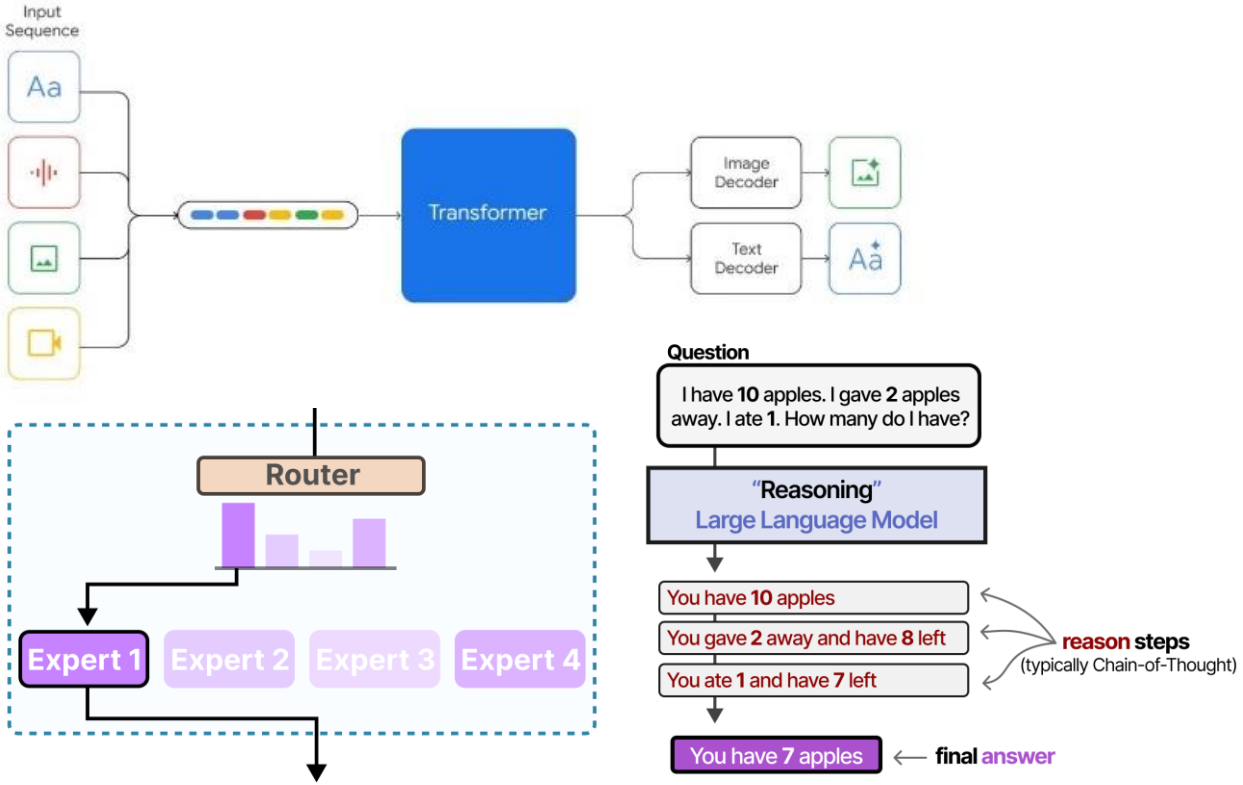
Sample 50

Prompt	Can we put pineapple on a pizza?
👍	Yes, pineapple a pizza is a recipe.
👎	No, pineapple on a pizza is a crime!

Image adapted from Liu, Y., Yao, Y., Ton, J.-F., Zhang, X., Guo, R., Cheng, H., Klochkov, Y., Taufiq, M. F., & Li, H. (2023). Trustworthy LLMs: A Survey and Guideline for Evaluating Large Language Models' Alignment (arXiv:2308.05374). arXiv. http://arxiv.org/abs/2308.05374



4. Multimodality, Mixture of Experts, Simulated Reasoning



Multimodality

– LLMs wie GPT-4 und Gemini verarbeiten Text, Code, Bild, Audio und Video – ein Modell für alle Modalitäten.

Mixture of Experts (MoE)

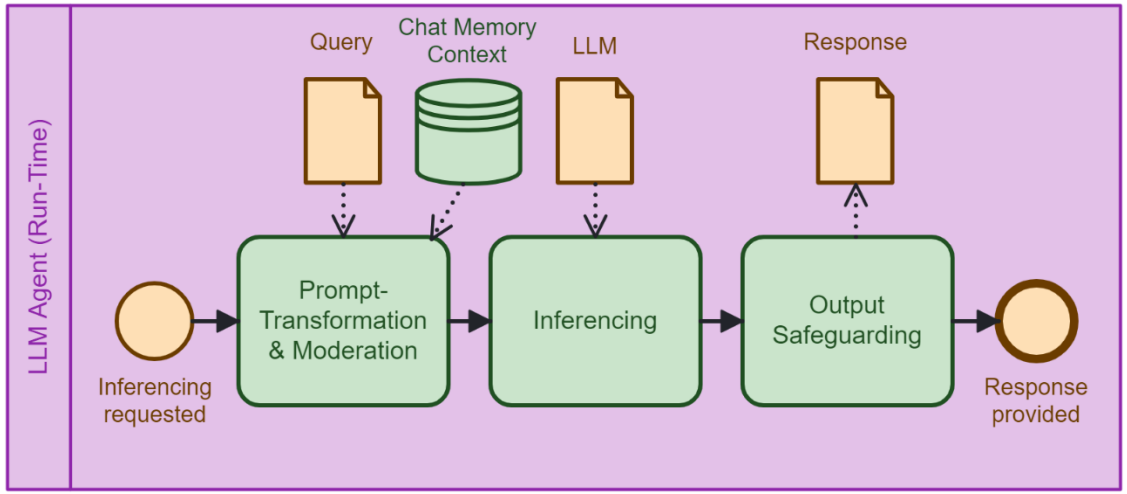
– Mehrere spezialisierte «Experten»-Netze, nur wenige pro Anfrage aktiv → effizient & leistungsstark (z. B. Mixtral 8×7B).

Simulated Reasoning

– LLMs simulieren schrittweises Denken (Chain-of-Thought). Neue Modelle wie o1 oder DeepSeek-R1 fokussieren auf simuliertes Reasoning statt reine Textgenerierung.

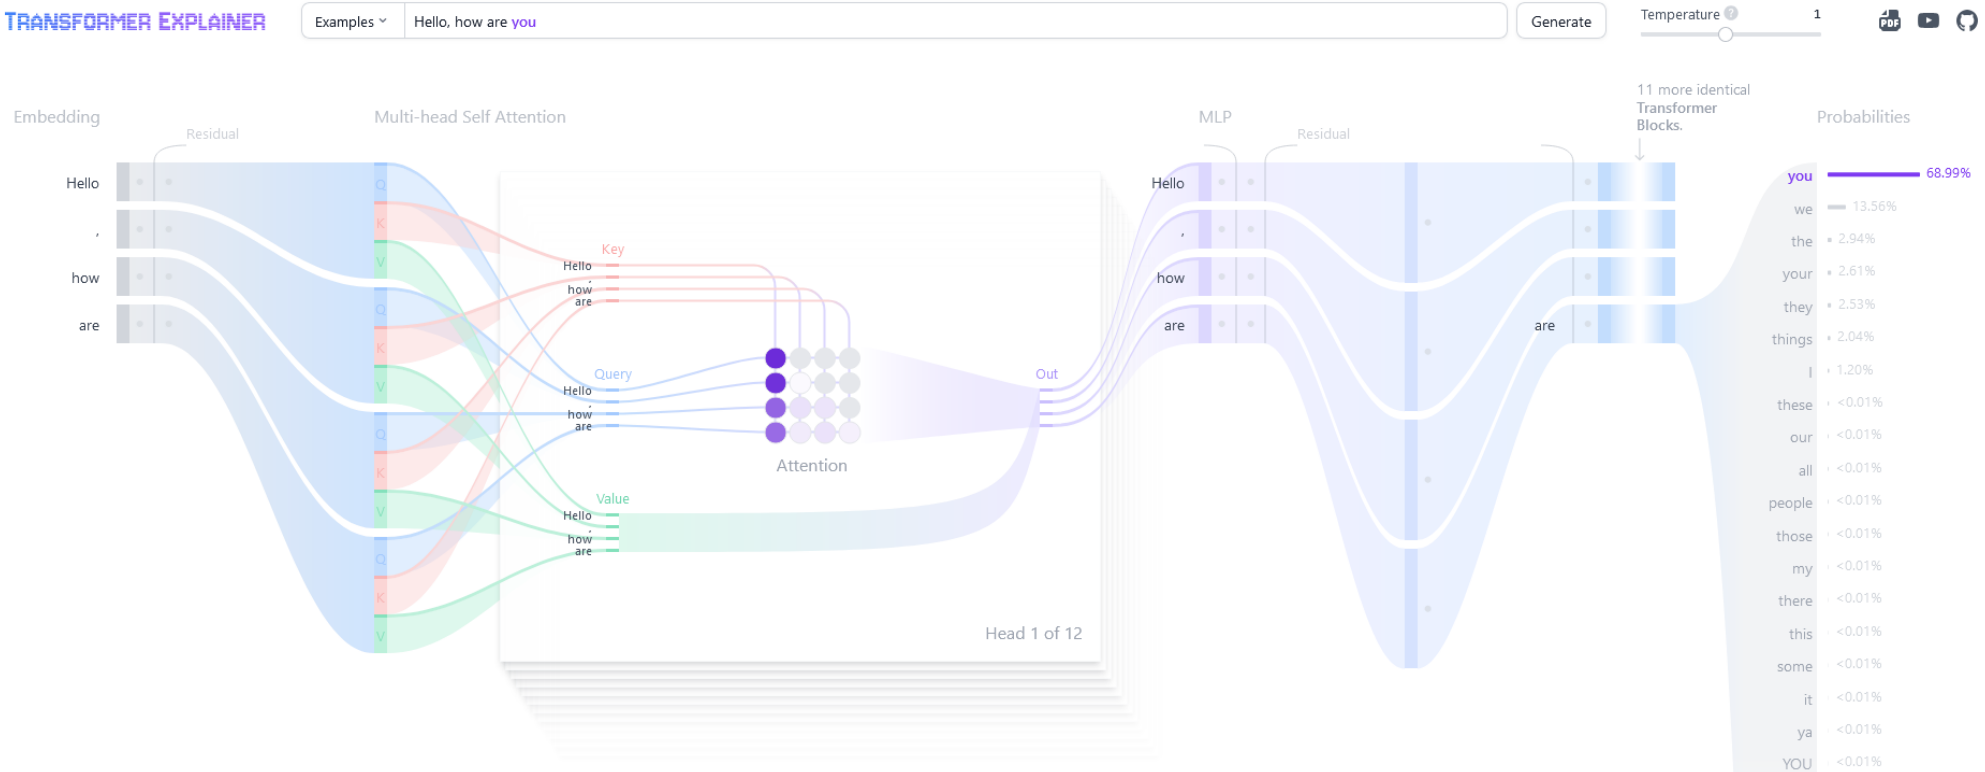
LLM Inferencing

LLM Inferencing



1. Question: Eine Person stellt eine Frage im Chat (z.B. ChatGPT).
2. Prompt transformation: Die Abfrage wird zusammen mit der Systemanweisung in einen Prompt transformiert.
3. Response generation: Das Sprachmodell (LLM) verarbeitet den Prompt im Inferenzprozess.
4. Responses: Das erzeugte Ergebnis wird als Antwort an die Person zurückgesandt.

Transformer – Inference Sampling



See https://poloclub.github.io/transformer-explainer/

Transformer – Inference Sampling

… Pizza is a

Tokenization & Encoding

Embeddings & Transformer Blocks

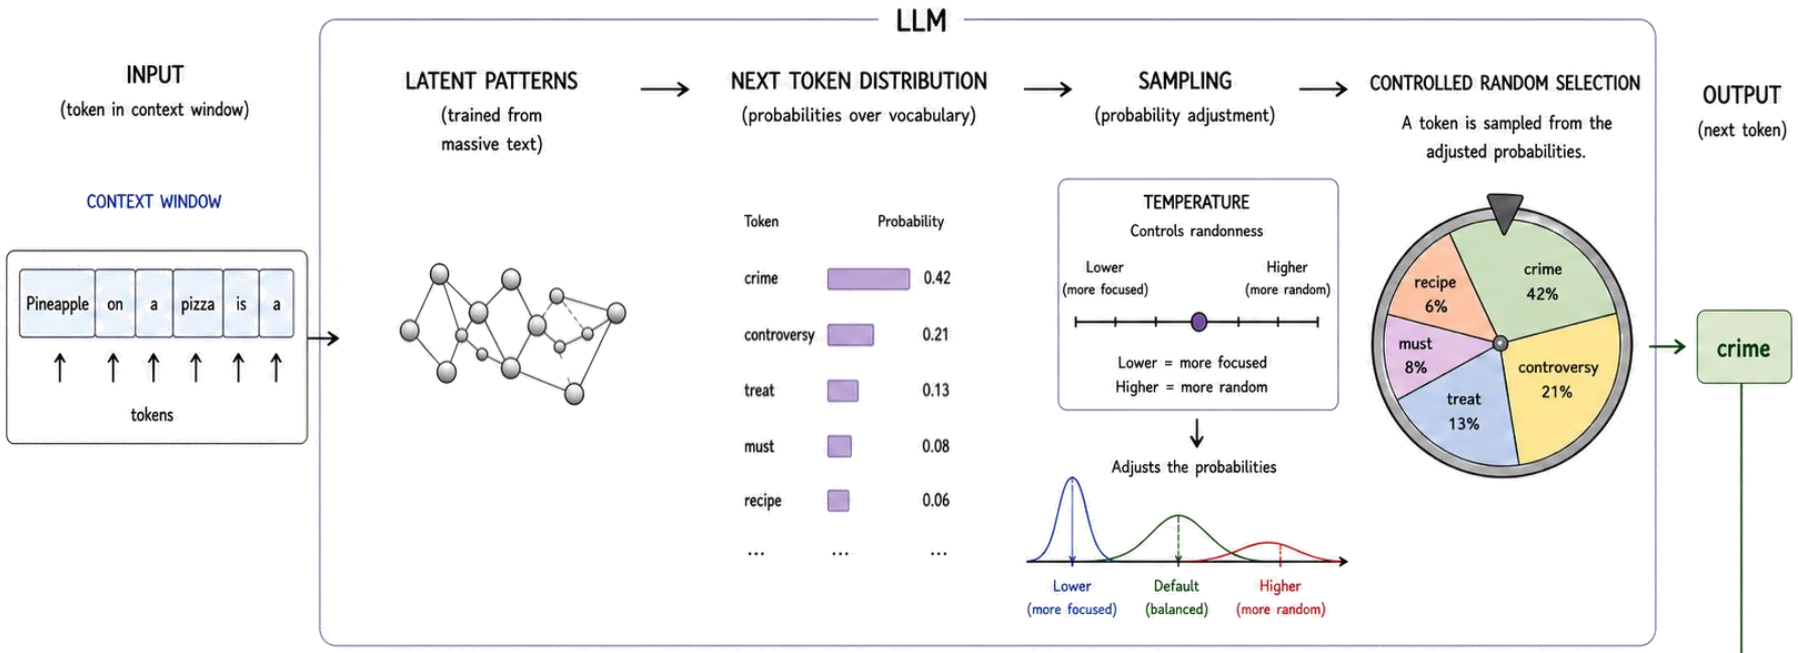
Temperature scal. Logits

Probability Softmax

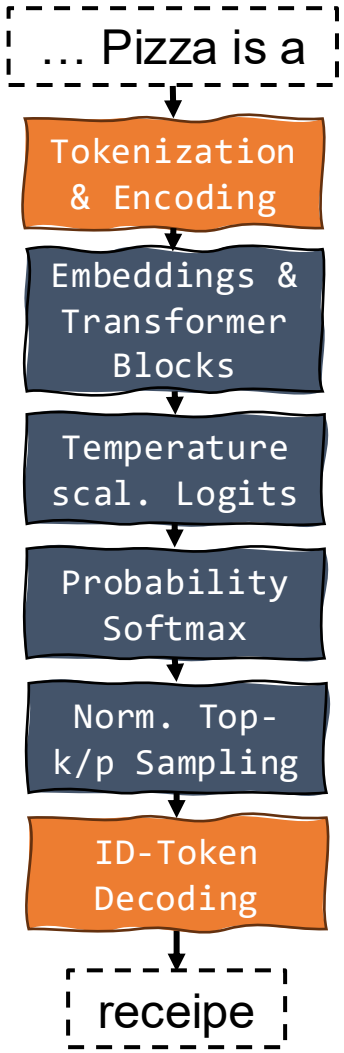
Norm. Top-k/p Sampling

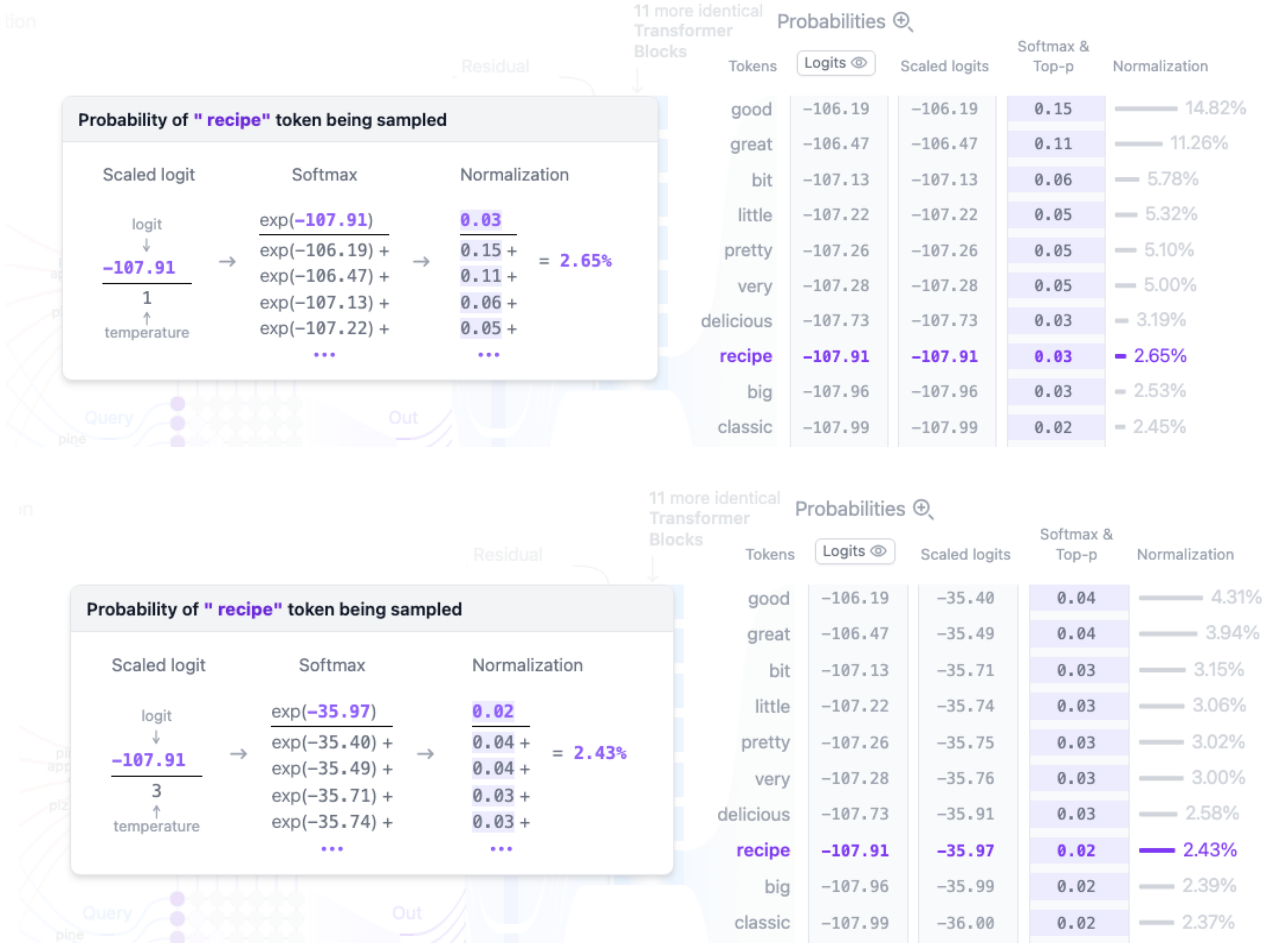
ID-Token Decoding

receipe

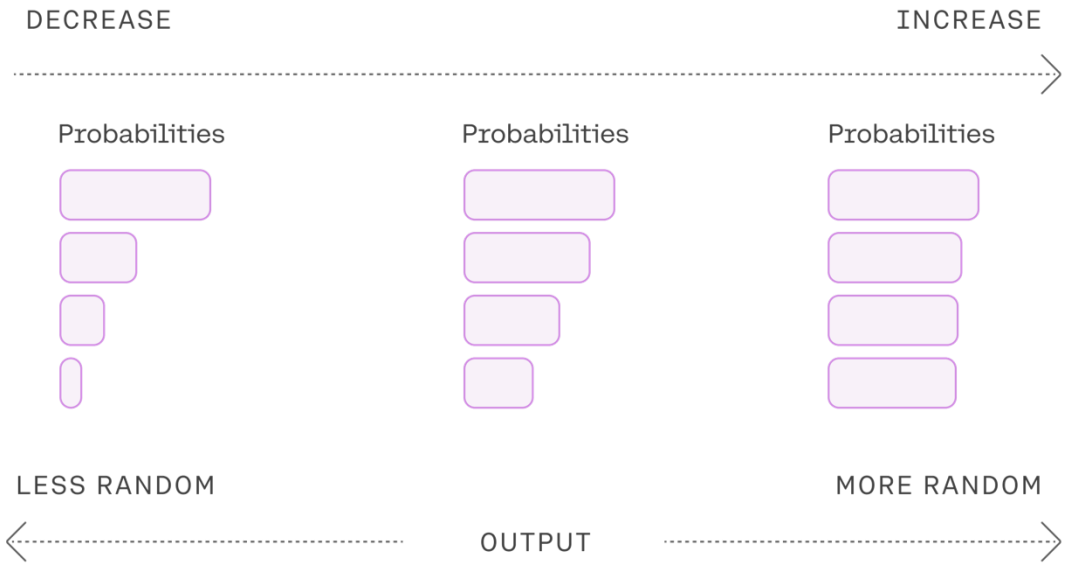


Transformer – Inference Scaling (e.g. **Temperature** = 1 vs. 3)





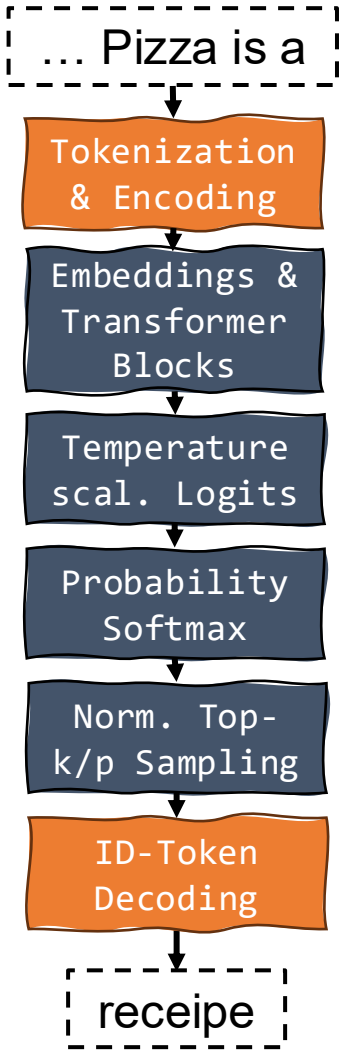
Transformer – Inference Scaling – Temperature

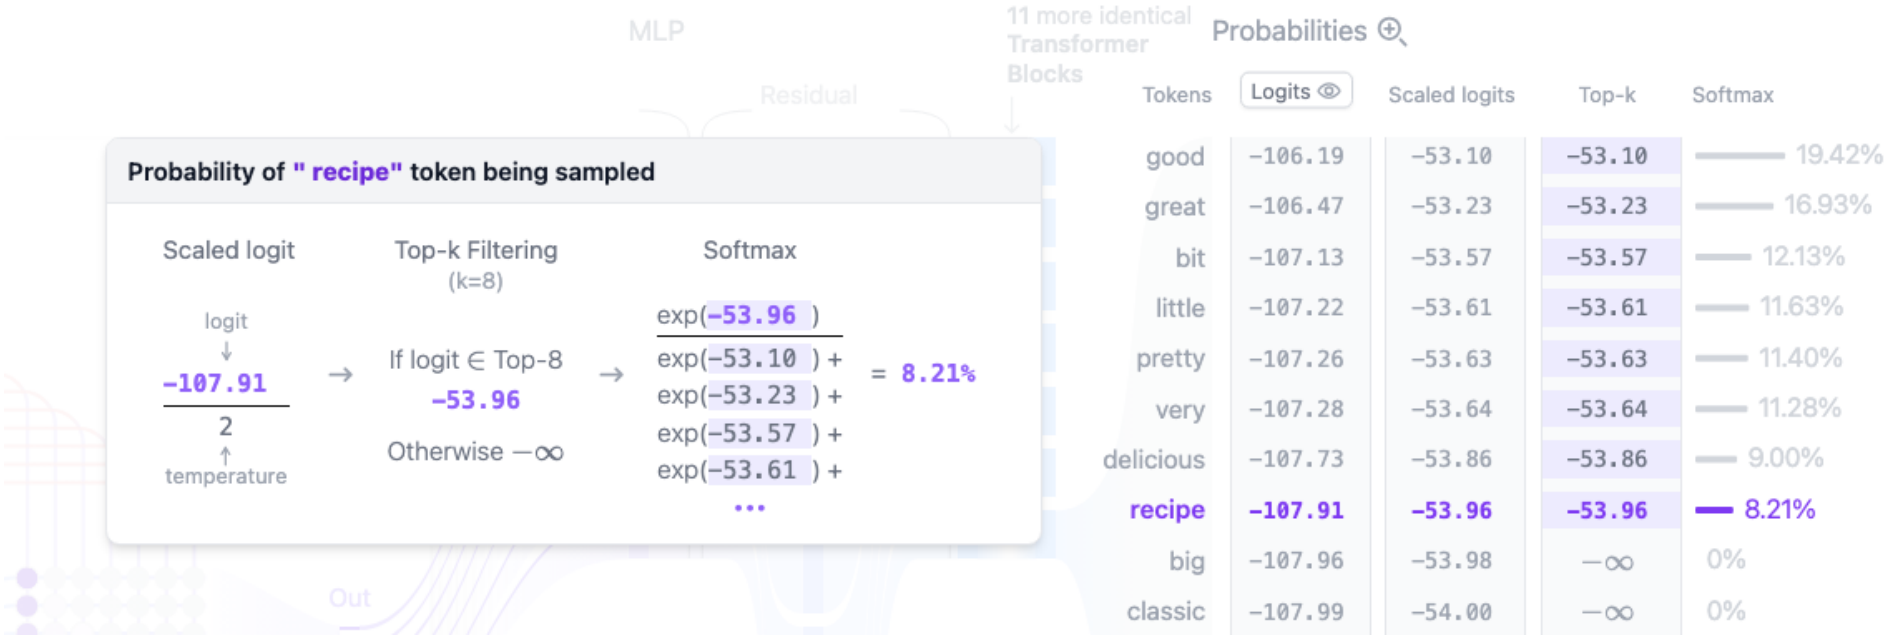


- Die **Temperatur** reguliert die Zufälligkeit der Antworten eines Sprachmodells.
  - Höhere Werte erhöhen die Variation (gleichmässige Verteilung), niedrigere Werte sorgen für Vorhersagbarkeit.
  - Einstellbar, um Kreativität oder Präzision zu erhöhen.

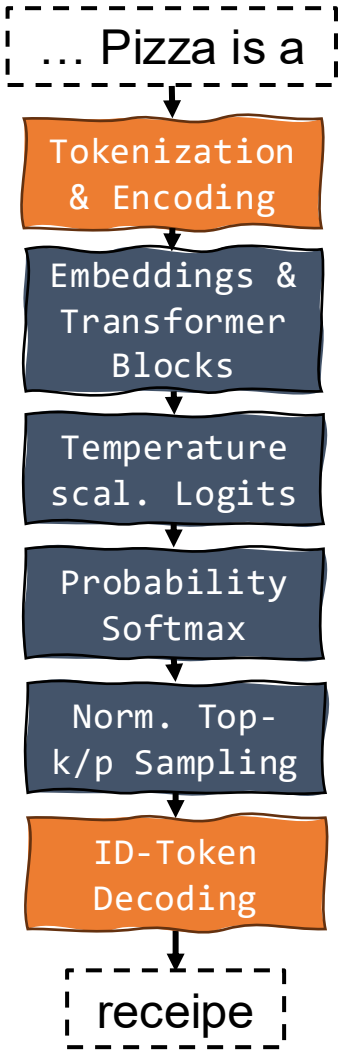
Cohere. (16. Mai 2023). Temperatur. Cohere Docs. https://docs.cohere.com/docs/temperature

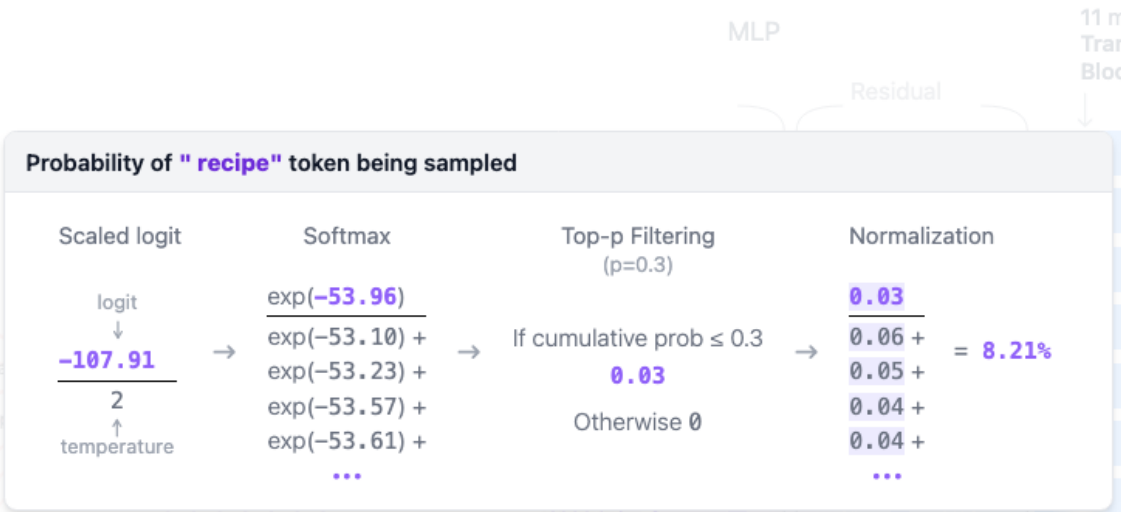
… Pizza is a Transformer – Inference Scaling (e.g. Temperature = 2) & Sampling (e.g. **Top-k** = 8)

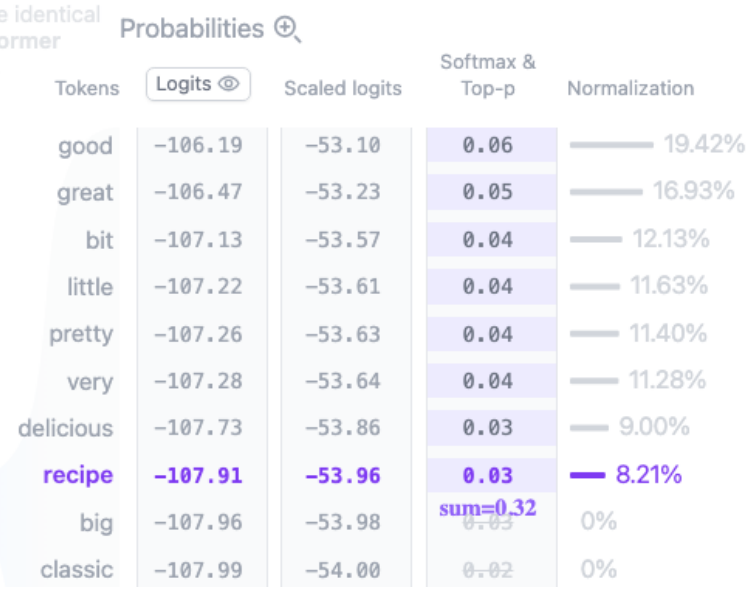




… Pizza is a Transformer – Inference Scaling (e.g. Temperature = 2) & Sampling (e.g. **Top-p** = 30%)



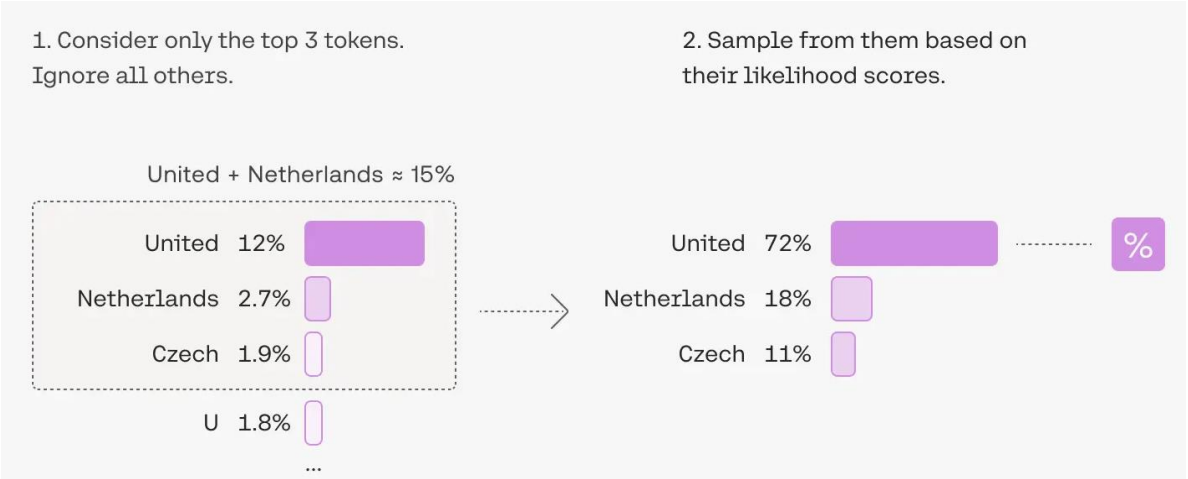




Transformer – top_k & top_p

- Parameter wie temperature, top_k und top_p steuern dabei, wie **viel Zufall** in die Auswahl einfliesst und wie deterministisch die Vorhersage ist.
- Top-k: **Begrenzt die Auswahl auf die k** wahrscheinlichsten Token bei jeder Vorhersage.
  - Zum Beispiel bedeutet top_k=3, dass nur die 3 wahrscheinlichsten Wörter berücksichtigt werden, während alle anderen ignoriert werden.
- Top-p (Nucleus Sampling): Bezieht nur die Token ein, deren **kumulative Wahrscheinlichkeit** unter einer festgelegten Grenze p liegt.
  - Mit top_p=0.15 werden z. B. die wahrscheinlichsten Token berücksichtigt, die zusammen mindestens 15% der Gesamtwahrscheinlichkeit abdecken.

top_k = 3



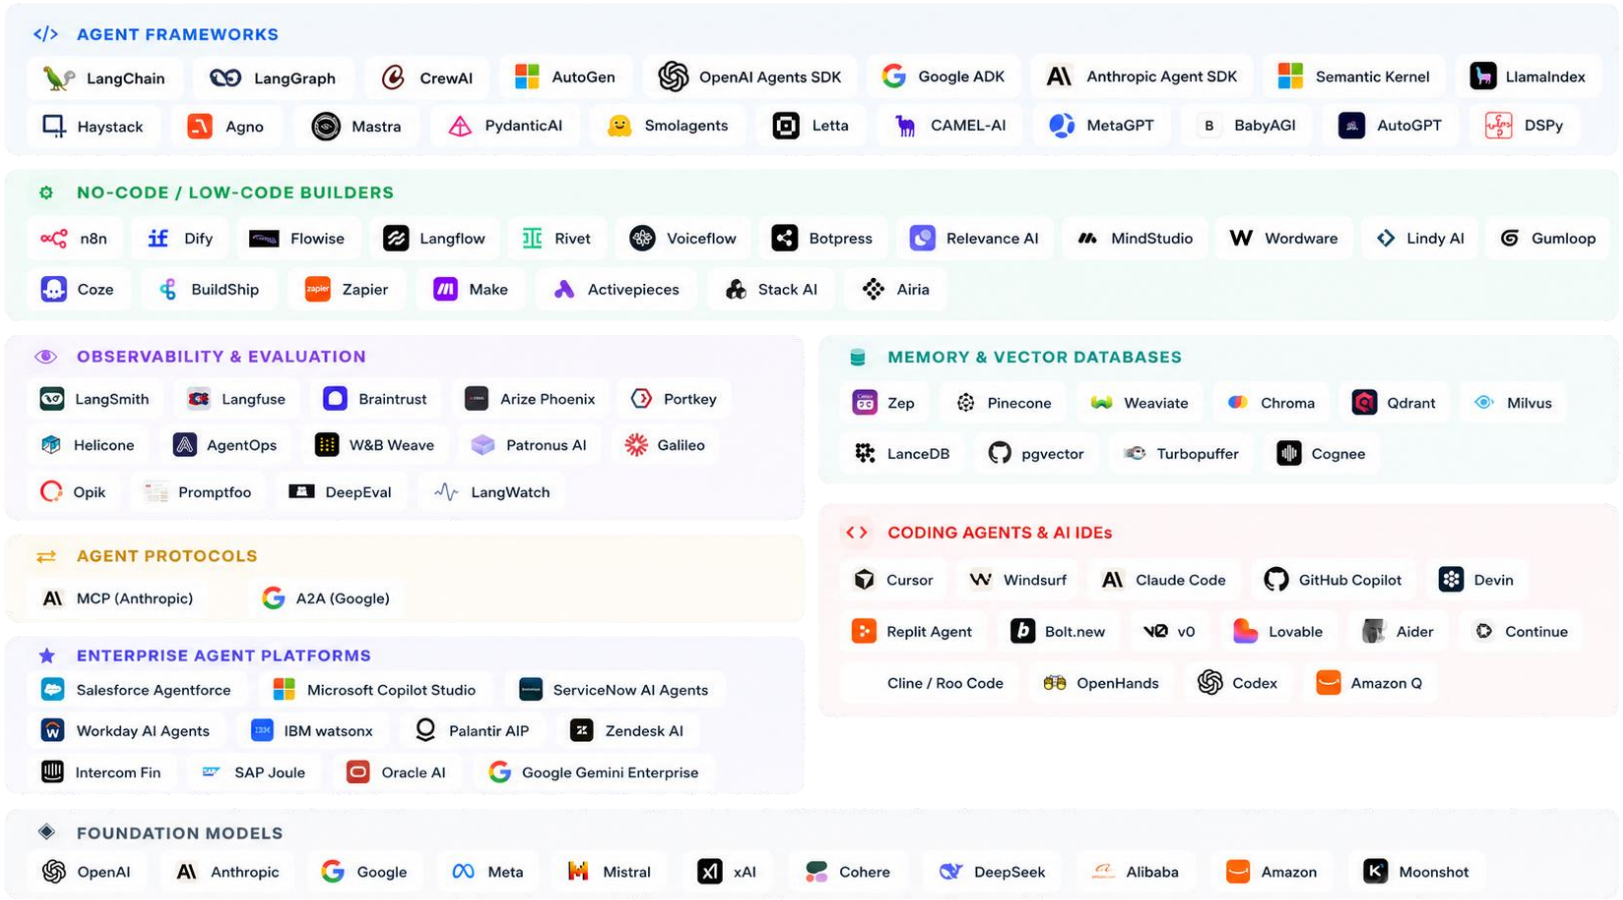
top_p = 0.15



Bilder: https://docs.cohere.com/v2/docs/advanced-generation-hyperparameters
Playground: https://huggingface.co/spaces/genaibook/token_probability_distribution

Prompt Engineering

Generative & Agentic Tooling Landscape



- Pro-Code Agent Frameworks:
  - LangChain, Haystack, LlamaIndex, CrewAI, AutoGen
- No-Code Agent Frameworks:
  - LangFlow, n8n, make.com, dify
- Playgrounds:
  - Hugging Face Playground, Vercel AI, OpenRouter
- Dialogue Frameworks:
  - Voiceflow, botpress
- UI & Chat Interfaces:
  - Gradio, Streamlit, Chainlit

Generative & Agentic Tooling Landscape (Pro-Code)

- LangChain: Allgemeines Framework für LLM-Anwendungen
  - Geeignet für Textgenerierung, Übersetzung, Zusammenfassung, Chatbots und komplexe Anwendungen
  - Bietet mehr sofort einsatzbereite Komponenten für die Erstellung vielfältiger KI-Workflows
- LlamaIndex: Spezialisiert für Such- und Abrufaufgaben
  - Ideal für die Generierung von Inhalten, die Dokumentensuche, Chatbots und virtuelle Assistenten
  - Besser geeignet für die Erstellung produktionsreifer RAG-Anwendungen mit schneller Datenabfrage und nahtloser Indizierung
- Haystack: Open-Source-Python-Framework für produktionsreife LLM-Anwendungen
  - Integriert mit den meisten grossen Modellanbietern und Datenbanken
  - Stabil und für Produktionsumgebungen empfohlen

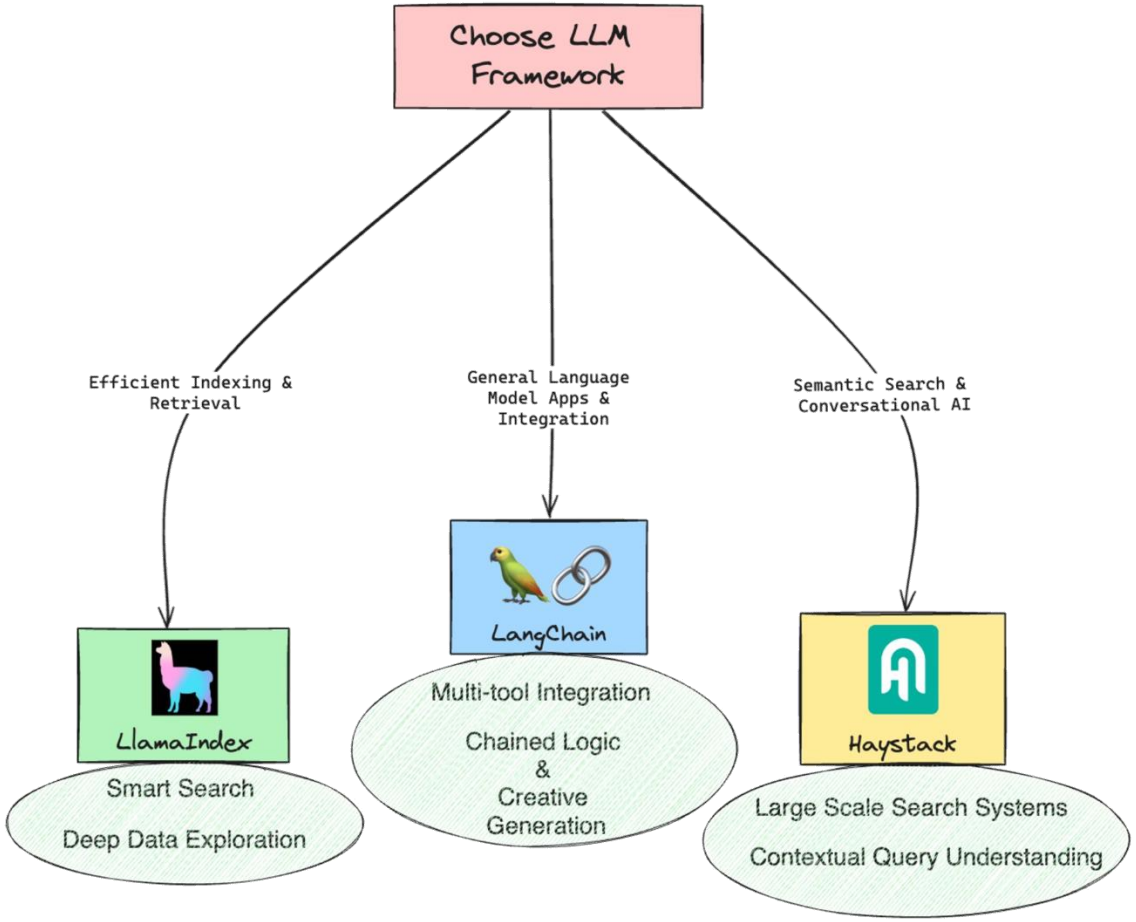


Bild von Pavan Belagatti von https://www.linkedin.com/posts/pavan-belagatti_llm-activity-7199670521012080642-rkPI

Single-turn Agent with Instruction



Prompt Template – ein iterativer Prozess

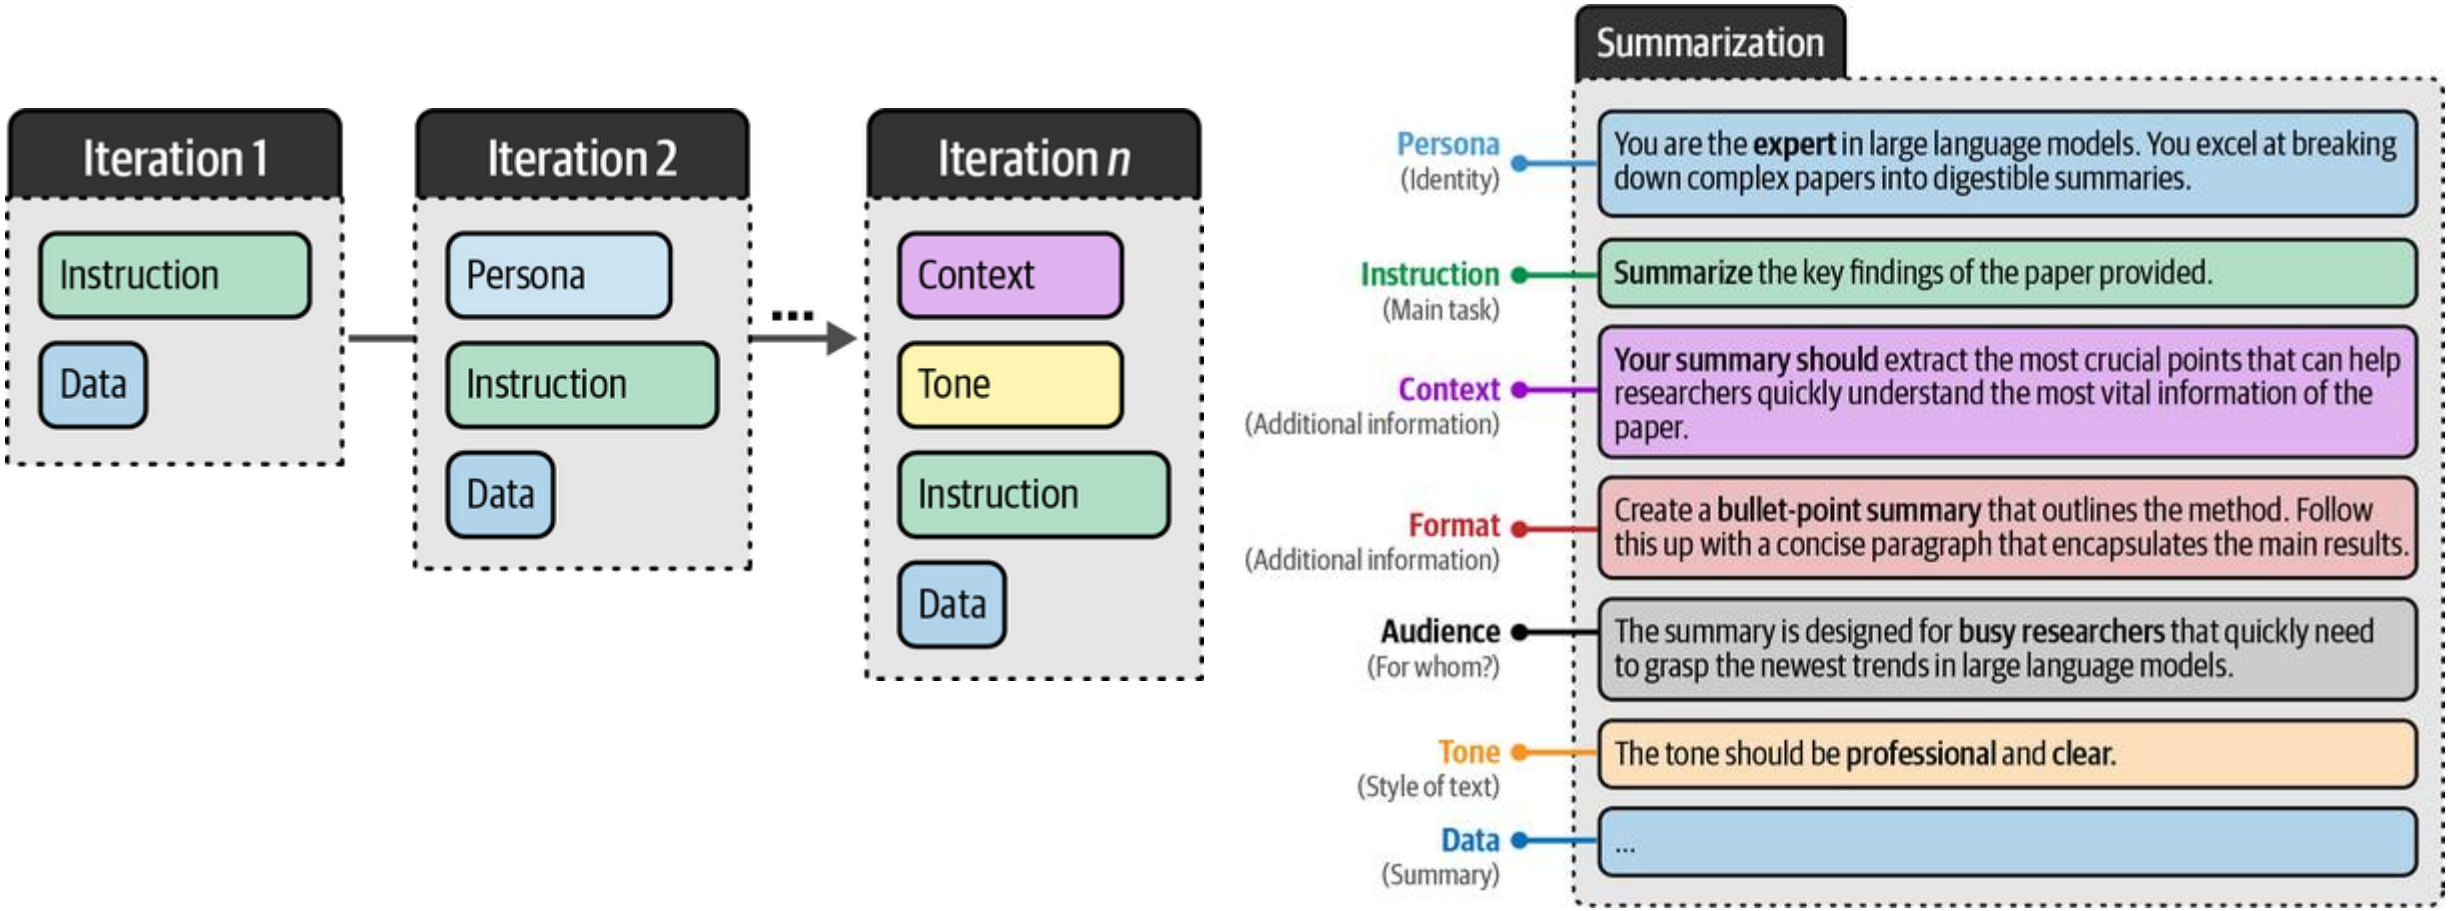
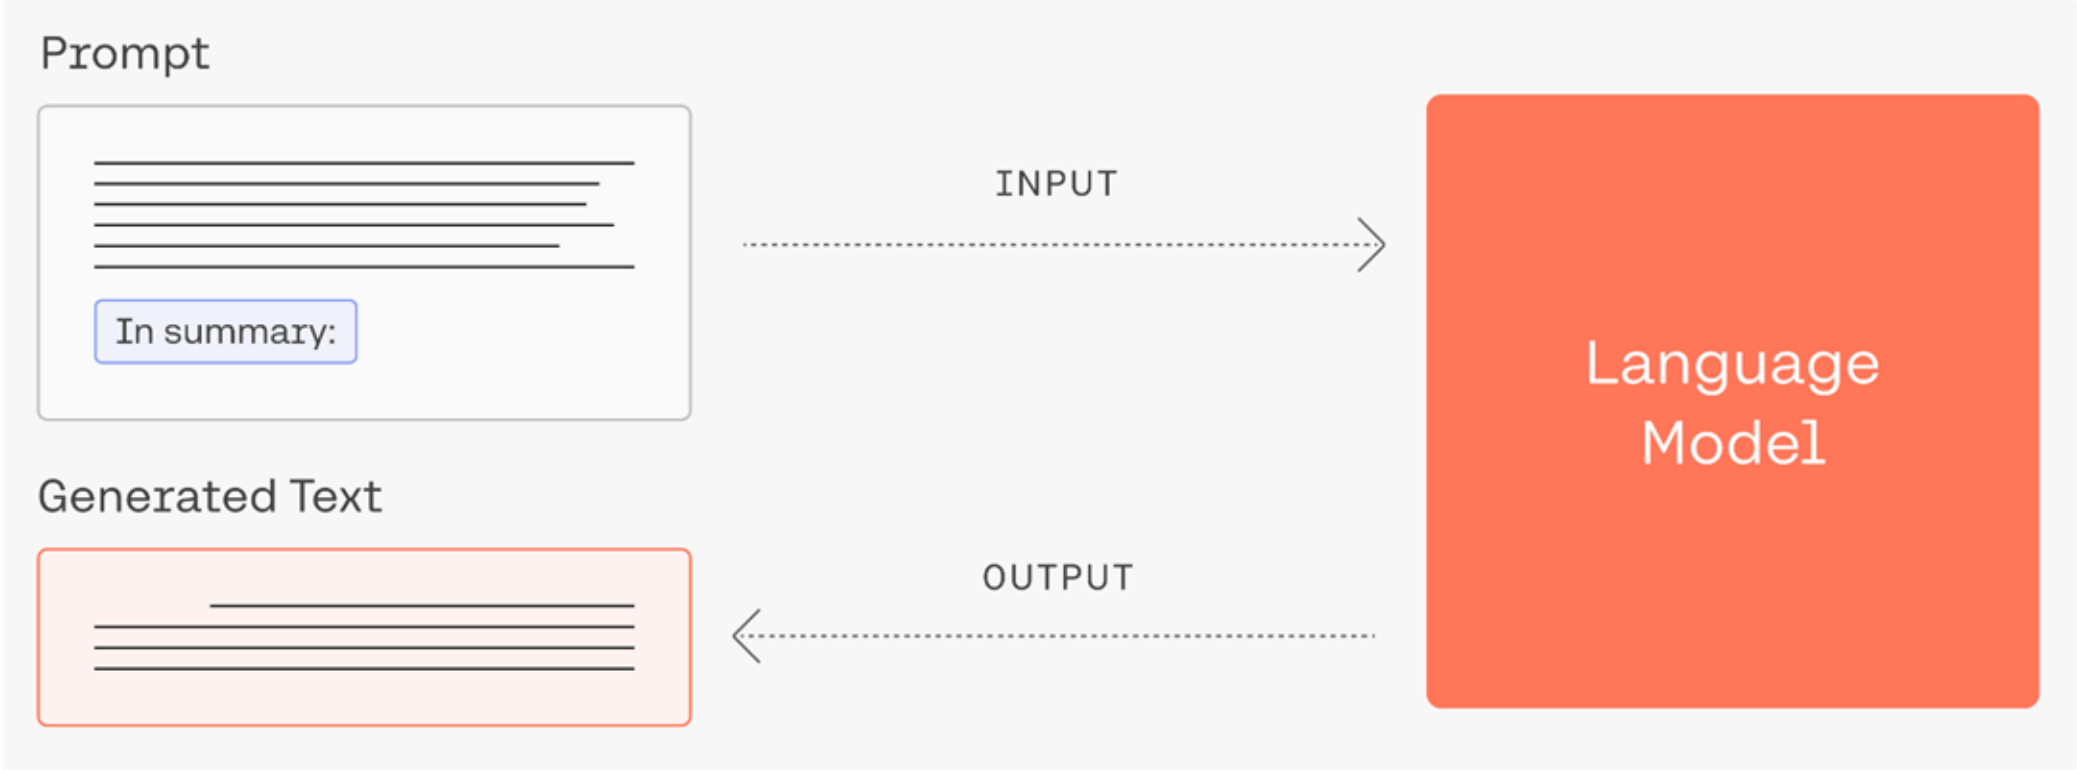


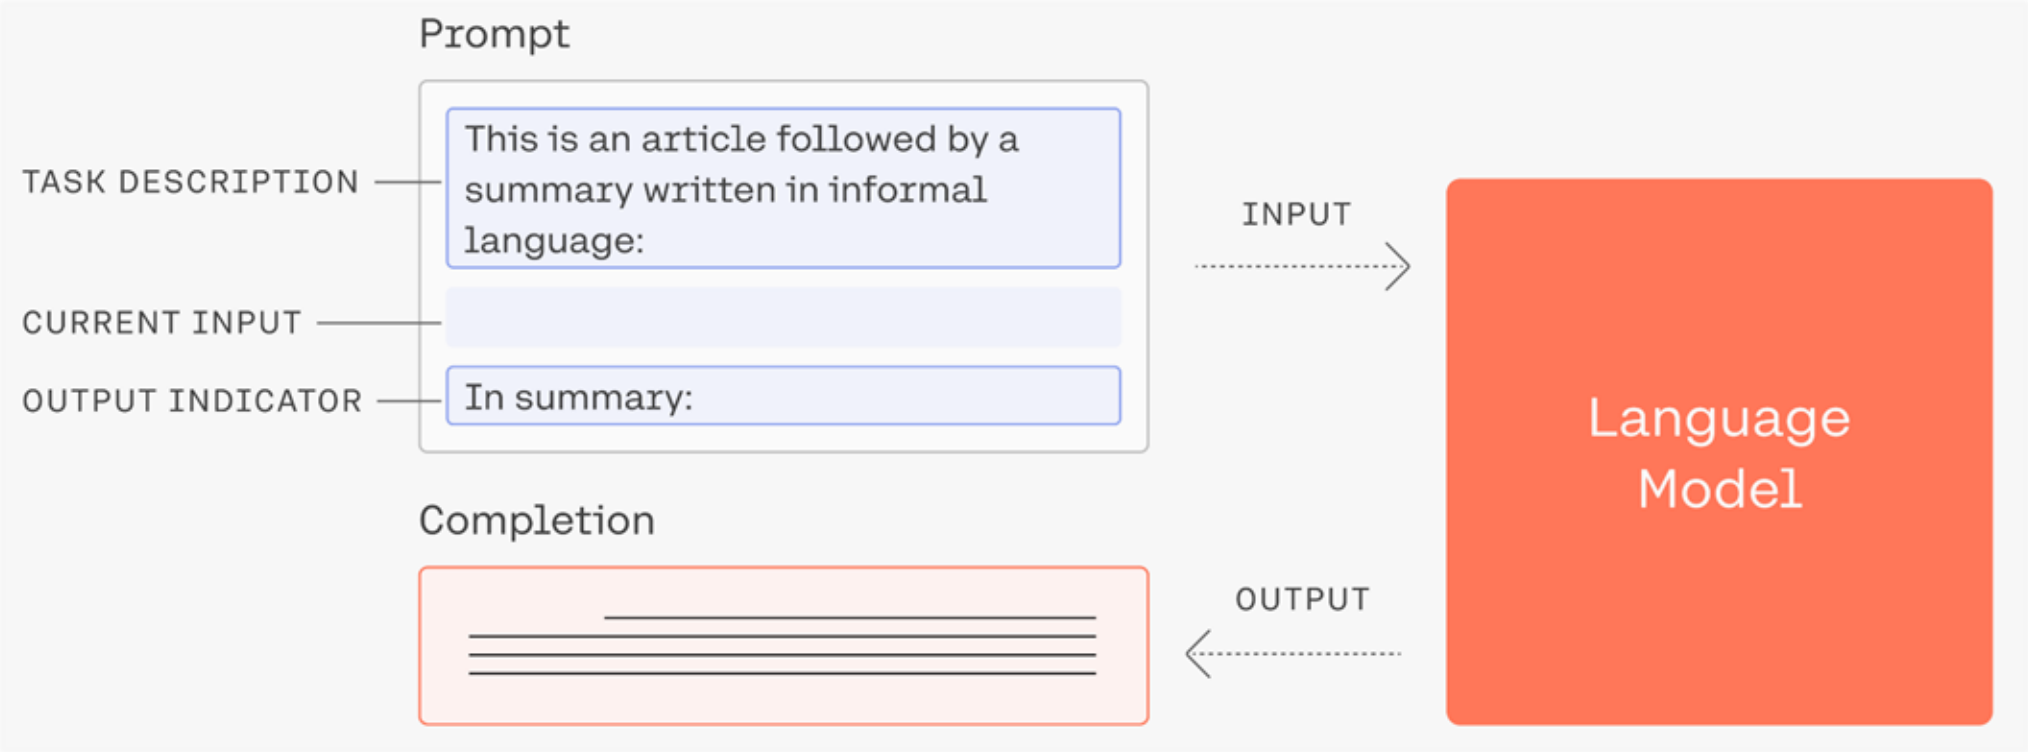
Bild: Alammar, J., & Grootendorst, M. (2024). Hands-on large language models: Language understanding and generation (First edition.). O'Reilly Media.

Prompt Engineering: Zero-Shot-Prompting



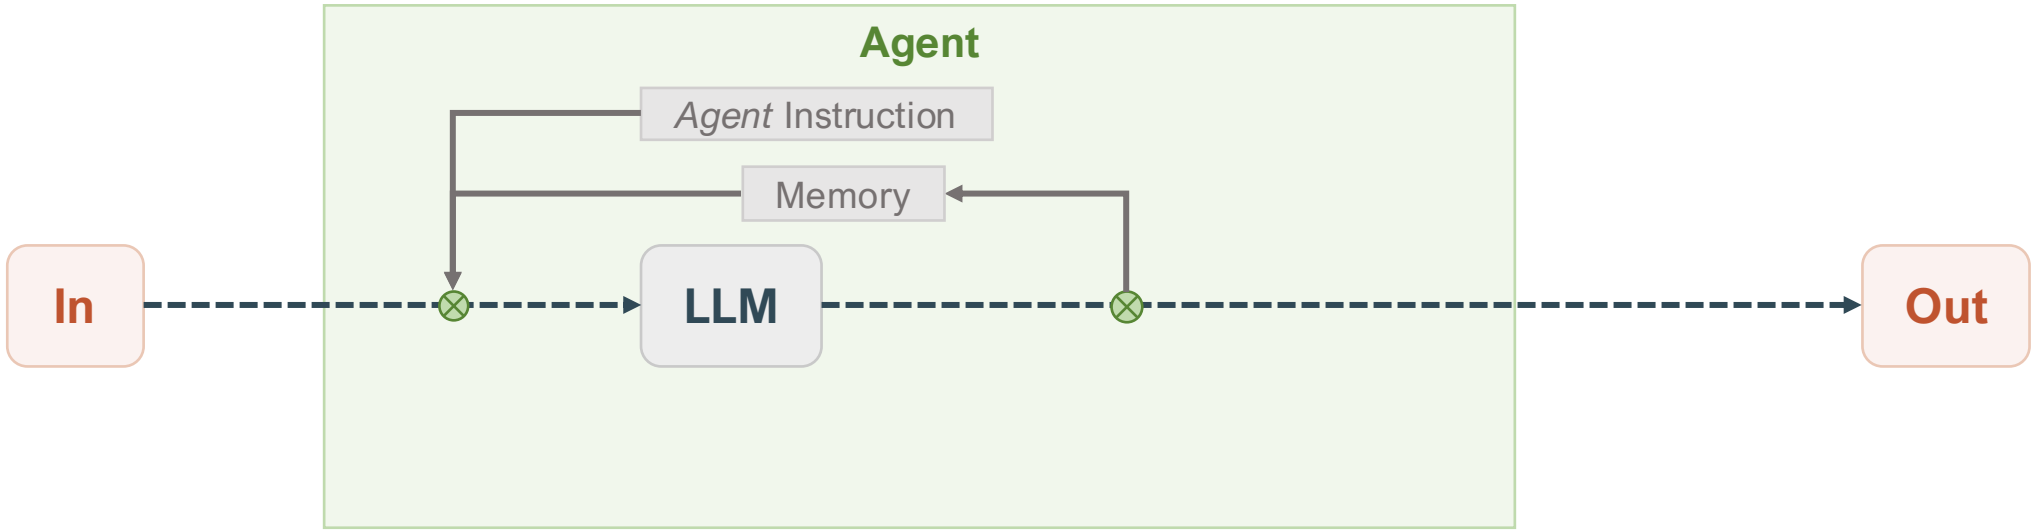
Cohere. (2023). Prompt Engineering. Cohere Docs. https://docs.cohere.com/docs/prompt-engineering

Prompt Engineering: Prompt-Template mit Task

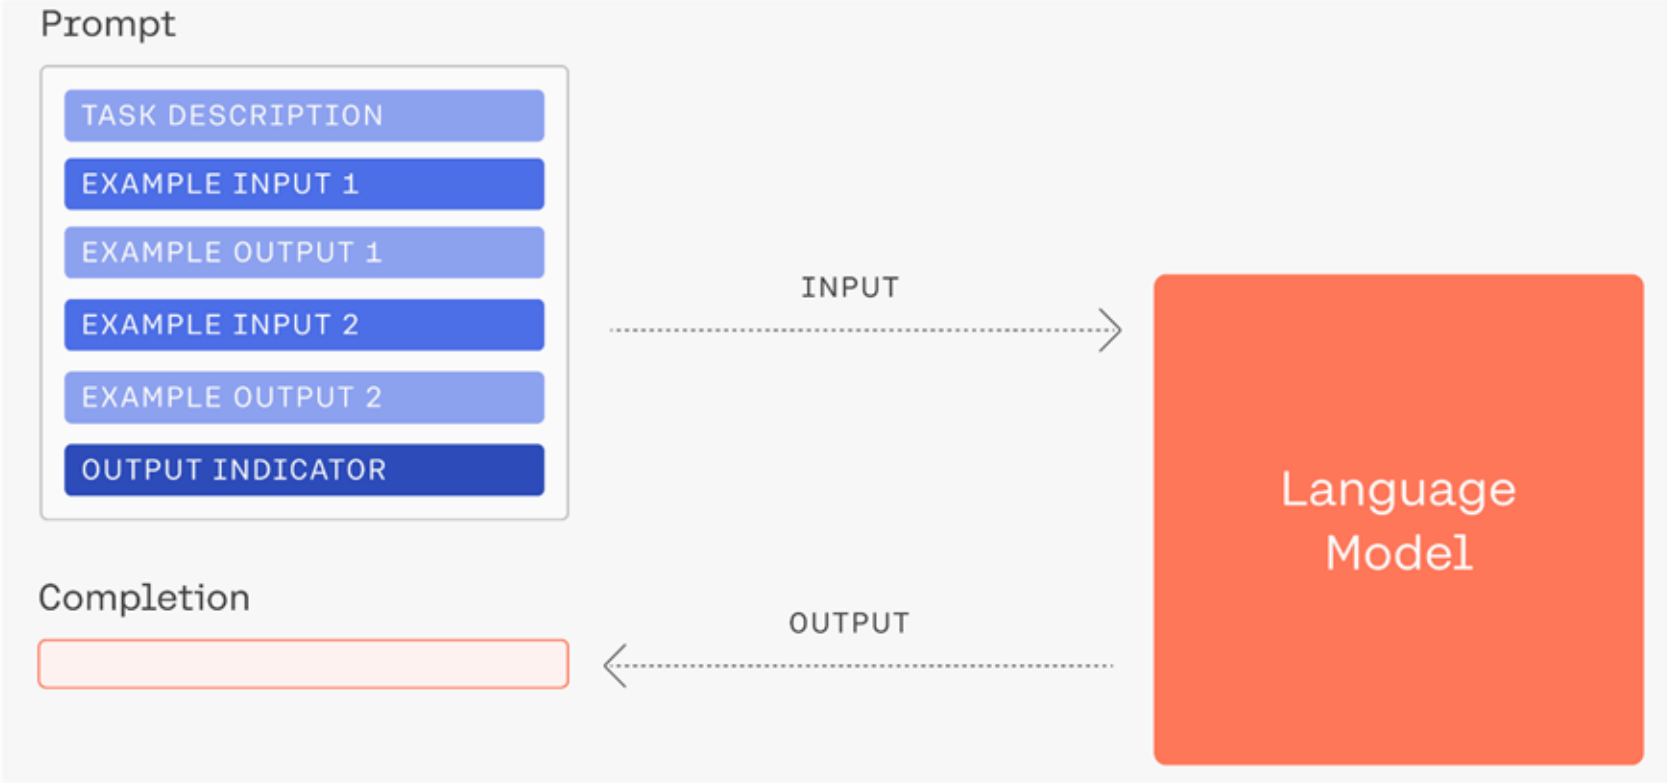


Cohere. (2023). Prompt Engineering. Cohere Docs. https://docs.cohere.com/docs/prompt-engineering

Single-turn Chat Agent

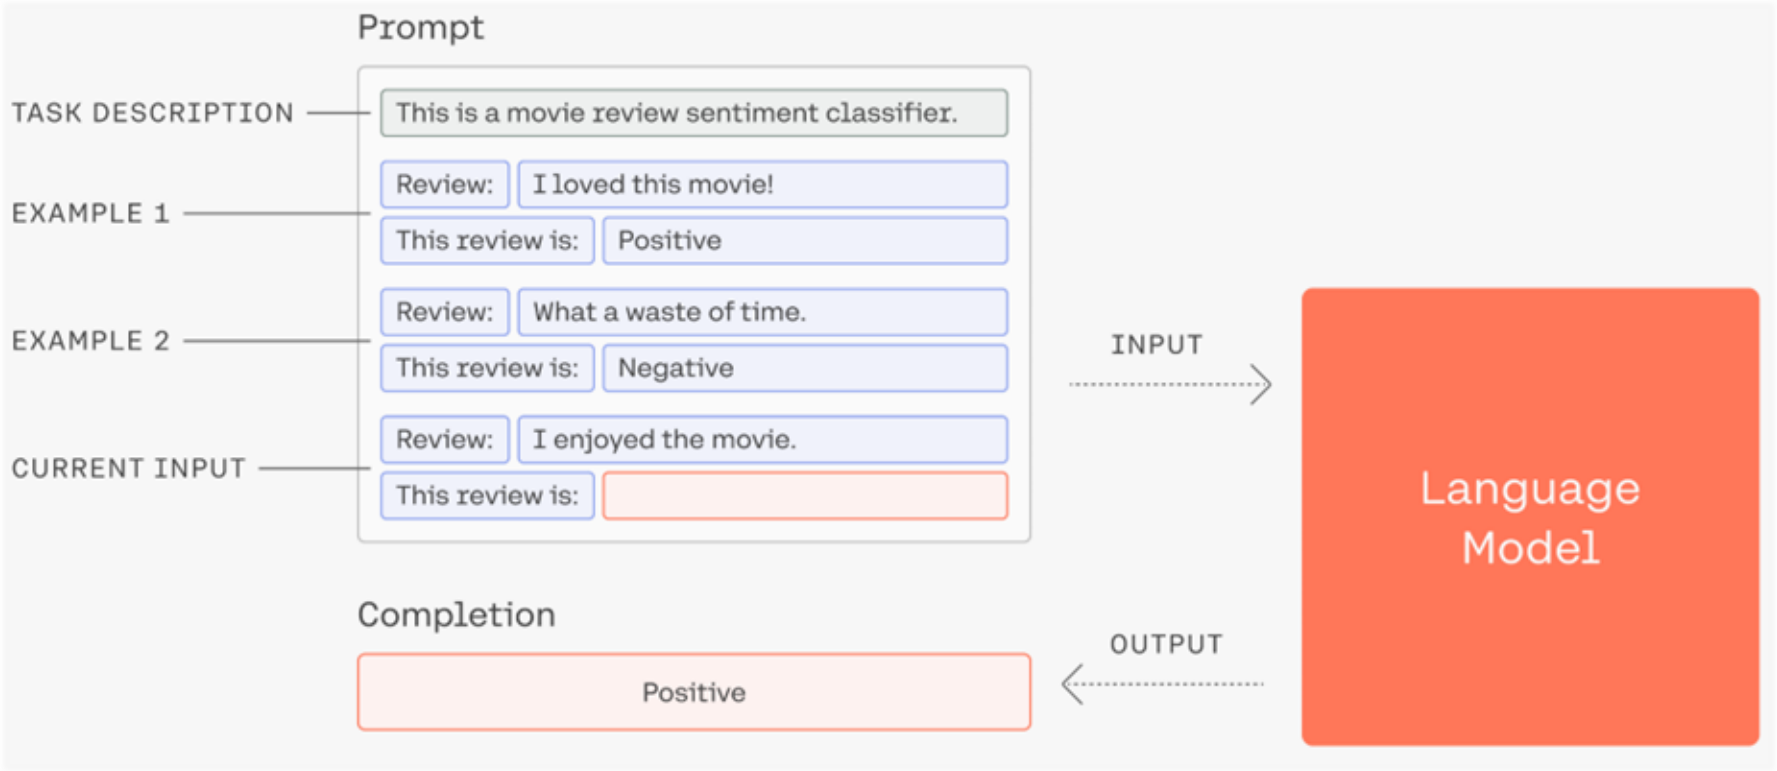


Prompt Engineering: Few-Shot Prompting (1)



Cohere. (2023). Prompt Engineering. Cohere Docs. https://docs.cohere.com/docs/prompt-engineering

Prompt Engineering: Few-Shot Prompting (2)



Cohere. (2023). Prompt Engineering. Cohere Docs. https://docs.cohere.com/docs/prompt-engineering

Prompt Engineering: Few-/One-Shot

- Few-Shot bezeichnet den Prozess, bei dem einem Basismodell zum Zeitpunkt der Inferenz eine kleine Anzahl (wenige) Beispiele zur Verfügung gestellt werden.
  - Beim One-Shot wird dem Basismodell nur ein einziges Beispiel zur Verfügung gestellt.
  - Beim Zero-Shot sind keine Beispiele zulässig.

Zero-shot

The model predicts the answer given only a natural language description of the task. No gradient updates are performed.

```
1  Translate English to French:        ← task description
2  cheese =>                           ← prompt
```

One-shot

In addition to the task description, the model sees a single example of the task. No gradient updates are performed.

```
1  Translate English to French:        ← task description
2  sea otter => loutre de mer          ← example
3  cheese =>                           ← prompt
```

Few-shot

In addition to the task description, the model sees a few examples of the task. No gradient updates are performed.

```
1  Translate English to French:        ← task description
2  sea otter => loutre de mer          ← examples
3  peppermint => menthe poivrée        ←
4  plush girafe => girafe peluche      ←
5  cheese =>                           ← prompt
```

Brown et al (2020). Sprachmodelle sind Few-Shot-Lerner.